

分类号_____

UDC_____

学 号_____

重慶大學

硕士学位论文

论文题目：基于人工神经网络的图像压缩方法研究

论文作者：黄雪梅

指导教师姓名、
职称、工作单位：唐治德 教授 重庆大学

申请学位级别：硕士 专业名称：电气工程

论文提交日期：2005 年 4 月 15 日 答辩日期：2005 年 5 月 21 日

学位授予单位：重庆大学 授位日期：2005 年 月 日

答辩委员会主席：袁 春 教授

论文评阅人：袁 春 教授 吕厚余 教授

2005 年 4 月 15 日

重庆大学硕士学位论文

基于人工神经网络的图像压缩方法研究



硕士研究生：黄雪梅

指导教师：唐治德 教授

学科专业：电气工程

重庆大学电气工程学院

二〇〇五年四月

Master Degree Dissertation of Chongqing University

**Image Compression Based on Artificial
Neural Network**



Ms.D. Candidate: Huang Xue-mei

Supervisor: Prof. Tang Zhi-de

Major: Electrical Engineering

**College of Electrical Engineering of
Chongqing University**

April 2005

摘 要

基于神经网络的图像压缩技术，在理论和技术上开辟了图像压缩的新途径。本文深入研究了基于 BP（Back-Propagation）网络和自组织特征映射网络的图像压缩方法，并在针对原始的自组织特征映射网络（SOFM，Self-Organizing Feature Map）矢量量化的缺点的基础上提出了改进的矢量量化方法，由此引发了众多新型神经网络图像压缩系统的研究与探讨，使其技术本身更具应用前景。

本文的研究工作主要分为两大部分：BP 网络图像压缩和 SOFM 矢量量化，前者包括单个 BP 网络和多级 BP 网络图像压缩方法研究；后者主要包括原始 SOFM 矢量量化、基于 Hopfield 网络的图像边缘检测以及边缘保持 SOFM 矢量量化。

归纳起来，本文主要围绕下面的层次和思想展开：

（1）BP 网络能够直接提供数据压缩能力，首先从探讨 BP 算法入手，剖析基于 BP 网络的图像压缩的机理，深入研究它在图像压缩中的应用及其关键技术，分别应用 BP 算法的各种学习规则来实现图像压缩，通过一系列实验，分析和总结了压缩性能与各种网络参数之间的关系，这是本论文工作的一个重要部分。

（2）在单个 BP 网络实现图像压缩的基础上，结合图像块间的相关性，提出了多级 BP 网络实现图像压缩的思想，分析了基于多级 BP 网络的图像压缩的网络模型，深入研究了多级网络的嵌套式训练算法，并在现有条件下实现了图像压缩与图像重建，从而实现高压缩比，这是本论文的一种尝试。

（3）研究了自组织特征映射网络（SOFM）的算法以及结构，探讨了矢量量化的有关理论，并在此基础上分析 SOFM 在矢量量化中的应用及其关键技术，最后用 SOFM 实现矢量量化，从而实现图像压缩，并分析各种参数对重建图像性能的影响，这是本论文工作的另一个重要部分。

（4）本文的创新之二在于用 Hopfield 网络进行图像边缘检测，这与传统的图像边缘检测方法完全不同，利用 Hopfield 网络的并行结构，提高了计算速度，并且实现了基于图像内容的边缘检测，从而运用边缘检测结果计算出图像子像素块的统计特性和边缘特性。

（5）针对 BP 网络图像压缩和原始 SOFM 图像压缩的一个致命缺点——重建图像的边缘模糊，将待压缩图像的边缘特性融入自组织特征映射网络的权值修正过程中，从而提出了一种边缘保持的 SOFM 矢量量化方法，实验证明该方法是行之有效的，应用改进方法的重建图像具有更好的边缘特性和视觉效果。这种方法的

提出是本论文的主要创新之处。

大量实验表明，本文的研究工作不仅推进了神经网络图像压缩的实用化进程，而且为神经网络图像压缩理论提供了更广阔的研究空间。

关键词：图像压缩；人工神经网络；自组织特征映射；矢量量化；边缘检测

ABSTRACT

Image compression based on artificial neural network provides a novel way for investigation of theory as well as technique in the field of image compression. In this paper, we discuss deeply image compression based on back-propagation (BP) neural network and self-organization feature mapping (SOFM) network. Then, we propose a modified vector quantization (VQ) method aiming at the deficiency of original SOFM VQ, which not only demonstrates the potentials of the proposed methods, but also provides a profound insight into the theory of image compression based on artificial neural network.

In this paper, two main parts are presented: image compression based on BP neural network and image compression based on SOFM VQ. The former includes image compression based on single and hierarchical BP neural network. The latter mainly includes original SOFM VQ, edge detection from image based on Hopfield network and edge preservation SOFM VQ.

In sum, this paper is developed according to the following hierarchy and research mechanism.

(1) BP neural network can provide the ability of data compression directly. So we firstly discuss BP algorithm and explode the mechanism of image compression based on BP neural network. Then we make a study of the key technology in the application and several kinds of learning rules are used to compress the static image. After a series of experiments are executed, we analyze and summarize the relationship between the compression performance and the parameters of BP neural network. This is a main part of this paper.

(2) In combination with the correlativity between image blocks, we propose the idea of image compression based on hierarchical BP neural network. The further analysis is conducted in the network model and the nested training algorithm. Finally image compression and image reconstruction are accomplished respectively. This method can achieve higher compression ratio and it is a try as well as one of the innovations.

(3) The algorithm and architecture of SOFM neural network and the theory of VQ are discussed. Further discussion is made about the key technology in the application. And the VQ based on SOFM is executed and finally we analyze all kinds of parameters have influence on reconstructed image performance. This is the other main part of this paper.

(4) The other innovation is extracting edges from image by Hopfield neural network, which is so different from all traditional methods. Using the parallel structure of Hopfield neural network, computation speed is greatly increased and the edge detection based on contents is accomplished. And the statistical feature and edge feature of subimages are calculated according to the result of edge extraction.

(5) Aiming at the fatal difficulties of image compression based on BP neural network and original SOFM VQ——edge distortion of the reconstructed image, the edge feature of image is melt into the process of modifying for the weight of SOFM neural network. So a new SOFM VQ method based on edge preservation is proposed. Some experiments denominate its availability. Besides, the reconstructed image using the above method has the improved edge feature and the better visual effect. The modified method is the main innovation in this paper.

Experimental results of various simulations show that the research has great theoretical significance and widespread potential uses in practice.

Keywords: Image compression, artificial neural network, self-organizing feature map, vector quantization, edge detection.

目 录

中文摘要	I
英文摘要	III
1 绪论	1
1.1 图像压缩的目的和意义	1
1.2 各种图像压缩方法介绍	2
1.2.1 传统的图像压缩编码方法	2
1.2.2 新型图像编码技术	3
1.3 基于人工神经网络的图像压缩	4
1.3.1 人工神经网络用于图像压缩的原理与优势	4
1.3.2 基于人工神经网络的图像压缩编码方法分类	5
1.3.3 人工神经网络在图像压缩中的应用综述	6
1.4 基于人工神经网络的图像压缩的可行性分析	9
1.5 本文的研究内容	10
2 人工神经网络发展史及其基础理论研究	13
2.1 人工神经网络发展历史回顾	13
2.2 人工神经网络模型与网络结构	16
2.2.1 多输入神经元	16
2.2.2 基本网络结构	17
2.3 人工神经网络的分类	19
2.4 人工神经网络的学习规则	20
2.5 本章小结	21
3 基于 BP 网络的图像压缩	23
3.1 BP 算法研究	23
3.1.1 BP 网络结构及其算法	24
3.1.2 性能函数	24
3.1.3 偏导数的链法则	25
3.1.4 传输函数	26
3.2 BP 网络图像压缩	27
3.2.1 基本原理	27
3.2.2 计算模型	28
3.2.3 性能参数	29
3.3 关键技术	30

3.3.1 训练样本构造	30
3.3.2 训练算法	31
3.3.3 编码仿真结果	32
3.3.4 重建图像	32
3.4 实验结果与分析	32
3.4.1 实验一：采用不同的训练算法进行仿真	32
3.4.2 实验二：线性与非线性的比较	34
3.5 多级 BP 网络实现图像压缩	36
3.5.1 基于多级 BP 网络的图像压缩的网络模型	36
3.5.2 多级网络的嵌套式训练算法	37
3.5.3 实验结果分析	39
3.6 本章小结	40
4 基于自组织特征映射网络的图像压缩	41
4.1 矢量量化的理论研究	41
4.1.1 矢量量化的基本原理	41
4.1.2 矢量量化中的码书设计	42
4.2 SOFM 网络的理论研究	42
4.2.1 SOFM 网络的基本思想	43
4.2.2 一般的 SOFM 网络的学习规则	44
4.2.3 SOFM 网络的几何解释	46
4.2.4 SOFM 网络的自组织特性	46
4.3 基于 SOFM 网络的矢量量化	46
4.3.1 学习率 $\eta(t)$ 及邻域 $N_g(t)$ 的选择	47
4.3.2 SOFM 网络在图像压缩中的应用	48
4.4 实验结果与分析	50
4.4.1 竞争层神经元个数对压缩性能的影响	50
4.4.2 训练矢量个数对压缩性能的影响	51
4.4.3 学习速度与衰减常数对压缩性能的影响	51
4.4.4 邻域参数与初始码书对压缩性能的影响	52
4.5 本章小结	53
5 基于 Hopfield 网络的边缘检测和边缘保持的 SOFM 图像压缩	55
5.1 Hopfield 网络研究	55
5.1.1 离散型 Hopfield 网络及其稳定性分析	56
5.1.2 连续型 Hopfield 网络及其稳定性分析	57

5.2 用改进的 Hopfield 网络实现图像边缘检测	60
5.2.1 改进后的 Hopfield 网络及其算法	61
5.2.2 网络的训练步骤以及学习机理分析	62
5.2.3 边缘检测以及结果分析	63
5.2.4 输入矢量的整定以及结果分析	64
5.2.5 阈值处理以及结果分析	66
5.3 边缘保持的 SOFM 图像压缩	66
5.3.1 改进的自适应学习方法	67
5.3.2 基于 SOFM 网络的边缘保持矢量量化系统	68
5.3.3 实验结果	69
5.4 本章小结	70
6 总结与展望	71
6.1 本文总结	71
6.2 工作展望	72
致谢	73
参考文献	75
附录 A: 本文中出现的英文缩写及其含义	79
附录 B: Hopfield 网络的稳定性相关证明	81
附录 C: 作者在攻读硕士学位期间发表的论文	83

1 绪 论

1.1 图像压缩的目的与意义

人类获取的信息大多数来源于图像媒体,这说明图像是人类生活中信息交流最为重要的载体,是蕴含信息量最大的媒体。信息数字化处理是信息社会的一个重要标志。但图像信息数字化使电子信息技术领域面临的最大难题是海量数据的存储和传输问题。因此,数据压缩技术,尤其是图像数据压缩技术是解决问题的关键。通过图像冗余数据的减少可以达到图像压缩的目的,可以通过充分利用人眼的视觉特性和图像本身的统计特性来减小图像信息的冗余度,在保证图像质量的条件下实现图像压缩。正是由于图像压缩的必要性和可行性,所以许多致力于减少数据量和降低比特率,同时又尽量保持图像信号原有质量的压缩编码方案应运而生。

人们能够明显体会到图像压缩的现实意义:节省存储空间、节省 CPU 时间和节省传输时间。而且图像数据压缩具有明显的经济效益,其优点表现在:

- (1) 能够较快的传输各种信源,降低信道占用时间;
- (2) 能够在现有的信道上开通更多的并行业务,如电视、传真、可视图文等;
- (3) 能够紧缩数据存储容量,降低存储费用。

数字图像压缩编码是在经典信息论中的信源编码理论上发展起来的“古老而又新兴”的学科。1948 年,电视信号数字化的提出,标志着图像压缩编码研究工作的开始,1969 年在美国举行首届“图像编码会议”(Picture Coding Symposium 简称 PCS)^[1] 表明图像编码以独立的学科跻身于学术界。如今,作为信息高速公路主要技术之一的数据压缩技术已经成为计算机、通信、电子三个信息支柱产业的核心技术,也是现有电话网、计算机网、广播网三网逐步融合最终走向合一的技术基础之一。

目前,图像编码的方法繁多^[2-5],发展也相当迅速,根据不同应用目的而制定的图像压缩国际标准(CCITT H.26X, JPEG, JBIG, MPEG)^[6,7]相继推出,使得图像编码的理论和技術得到了前所未有的发展;同时,随着数学、物理学、脑成像技术和计算机科学的发展,使得人工神经网络(Artificial Neural Network, ANN)理论的研究再一次成为人工智能领域研究的热点^[8]。作为和第一代电子计算机同时代产物的人工神经网络,由于其大规模并行处理和分布式信息存储的优势,并有良好的自适应性、自组织性和容错性,以及强大的学习功能、联想记忆功能^[8],促使人们寻找神经网络理论和图像压缩技术的结合点,克服传统图像压缩方法存在的问题,从而在理论和技術上开辟图像压缩的新途径。

因此,研究基于人工神经网络的图像压缩理论与方法在学术价值和实际应用方面都具有及其重要的意义。同时,这项十分新颖且处于探索阶段的技术,也给研究者带来了更大的挑战和更广阔的研究空间。

1.2 各种图像压缩方法介绍

1.2.1 传统的图像压缩编码方法^[3, 4, 6]

(1) 无损压缩

- 行程编码 (Run-Length) 编码技术:它是一种相对简单的一种编码,是指在一行扫描的像素中,比较相邻像素的幅度(如亮度)。当幅度有一个显著变化时,就说有一个行程存在。像素幅度的连续长度和终点位置标记是其重要参数。随终点位置标记方法不同,行程编码分为“行程终点编码”和“行程长度编码”。

- Huffman 编码压缩:它是一种比较有效的编码方法,也是一种长度不均匀的、平均码率可以接近信息源熵值的编码方法。其编码基本思想是:对于出现概率大的信息采用短字长的码,对于出现概率小的信息用长字长的码,以达到缩短平均码长,从而实现数据的压缩的目的。Huffman 编码的最高压缩效率可达到 8:1。

- 字典压缩方法:目前使用最广泛的字典压缩方法分为两种:一种是在压缩过程中,寻找当前等待进行压缩处理的数据串中是否在已经处理过的数据串中出现过,如果确实曾经出现过,则利用指向该已经进行处理数据串的指针代替当前进行压缩的数据串,此时,字典是隐式的,它用曾经处理过的数据描述;另外一种字典压缩算法是为输入数据创建一个短语字典,如果在当前对待压缩的数据流中发现字典中已经存在相应的短语,则利用该短语在字典中的相应索引值取代原始数据。字典压缩算法现在已经成功地用于某些图像数据的压缩处理。

- 算术压缩方法:它与 Huffman 压缩方法相似,都是利用比较短的代码取代图像数据中出现比较频繁的数据,而利用比较长的代码取代图像数据中出现频率较低的数据从而达到数据压缩的目的。其基本原理是任何一个数据序列均可表示成 0 和 1 之间的一个间隔,该间隔的位置与输入数据的概率分布有关。算术编码算法可以达到 100:1 的压缩比例。

(2) 有损压缩

- 预测编码方法:基于图像数据的空间和时间冗余特性,用相邻的已知像素(或图像块)来预测当前像素(或图像块)的取值,然后再对预测误差进行量化和编码。但是这种方法也能实现无损压缩。

- 变换编码:通常是将空间域相关的像素点通过正交变换映射到另一个频域上,使变换后的系数之间的相关性降低。其实现图像数据压缩的物理本质在于:经过多维坐标系中的适当的坐标旋转和变换,能够把散布在各个坐标轴上的原始数据,

在新的坐标系中集中到少数坐标轴上，因而可能用较少的编码比特数来表示一幅子图像，实现图像的压缩编码。从数学上来看，可用于图像压缩的正交变换的方法很多，如：Fourier 变换、Walsh-Hadamard 变换、正弦变换、余弦变换、斜变换、哈尔变换、K-L 变换等。

- 金字塔变换：首先将原始图像分解成许多不同的分辨率的子图像，并把高分辨率（尺寸较大的）的子图像放在下层，把低分辨率（尺寸较小）的子图像放在上层，从而构成了一个金字塔，借助于拉普拉斯金字塔算法，对图像的每一层分别量化、编码，并对视觉不敏感的层粗化，用较小的码字编码，从而达到压缩的目的。

- 子带编码：先将原始图像用若干数字滤波器（分解滤波器）分解成不同频率成分的分量，再对这些分量进行亚抽样，形成子带图像，最后对不同的子带图像分别用与其相匹配的方法进行编码，在接收端将解码后的子带图像补零、放大，并经合成滤波器的内插，将各子带信号相加，进行图像复原。子带编码与离散余弦变换编码相比的最大优点是复原图像无方块效应，因此得到了广泛的研究，是一种有潜力的图像编码方法。

- 矢量量化编码：它在图像编码中要优于标量量化，它利用相邻像素数据之间的高度相关性，将输入的图像数据序列分组，每一组 m 个数据被描述成一个有 m 个元素的矢量，然后逐个矢量进行量化编码。在该算法中，图像中的各种相关信息（如：各像素点间、各块之间以及相邻编码地址间等）可通过有效的码书设计得以充分的去除。矢量量化的压缩比可达到 40:1。

1.2.2 新型图像编码技术

- 第二代图像编码方法（Second Generation Coding）^[9,10]：针对传统编码方法中没有考虑人眼对轮廓、边缘的特殊敏感性和方向感特性而提出，不局限于 Shannon 信息论的框架，要求充分利用人类视觉系统中的生理和心理特性以及信源的各种性质以期获得高压缩比。

- 模型编码（Model-Based-Coding）^[11]：一种很有前途的低比特率编码方法，其基本出发点是在编码、解码端分别建立起系统的模型，它并不压缩实际的量化数据，而是采用一个表示景物（一般是人，人脸）的模型，传送的信息是告诉接收方如何改变模型以匹配输入景物。

- 人工神经网络编码（Artificial Neural Network Coding）^[11]：人工神经网络是一种模仿及延伸人脑功能的信息处理系统，它具有许多优良特性，如自学习特性、大规模并行处理、非线性处理特性和分布式存储特性等。人工神经网络在图像编码中已经获得了初步研究和应用，主要用于实现变换编码、非线性预测编码和矢量量化中的码书设计。

• 分形编码 (Fractal Coding)^[38,39]: 起源于 Mandelbrot 的分形几何学, 是建立在 M.Barnsley 开创的迭代函数系统基础上, 利用图像中像素点或子块之间的自相似性, 通过寻找自相似仿射变换系数, 对系数进行编码, 来达到图像压缩的目的。其依据是自然界具有标尺不变性的自相似性结构, 即分形特征。对于一幅图像只要传输或保存少量的系数就可通过仿射变换方式经多次迭代达到恢复近似的原始图像的目的。

• 小波编码 (Wavelet Coding)^[40]: 小波变换的本质是多分辨率或多尺度地分析信号^[41], 故小波分析特别适于分析非平稳信号, 而且它具有等 Q 分解信号的特性, 非常符合人的视觉系统对频率感知的对数特性。利用小波变换对图像进行压缩的原理与子带编码方法十分相似, 是将原图像信号分解成不同的频率区域 (在对原图像进行多次分解时, 总的的数据量与原数据量一样, 不增不减), 后续的压缩编码方法根据人的视觉特性及原图像的统计特性, 对不同的频率区域采取不同的压缩编码手段, 从而减少数据量。JPEG2000 就是基于小波变换的一种较新的图像压缩标准。

1.3 基于人工神经网络的图像压缩

1.3.1 人工神经网络用于图像压缩的原理与优势^[12-15]

人工神经网络是用来模拟人脑结构及性能特点的一个前沿研究领域。人工神经网络由大量简单的神经元模型所组成, 以模拟人脑的功能, 即联想记忆、推理思维等功能。它是一个非线性自适应动力系统, 也是一个信号与信息处理系统, 以求解传统信息处理方法难以解决或者不可能解决的问题。神经网络信息处理是一种全新计算机结构的新型智能信息处理系统, 它可以模仿人脑处理不完整的、不准确的、甚至处理非常模糊的信息, 并能联想记忆, 从部分信息中获取全部信息。

人脑在接受视觉感观传来的大量图像信息后, 能够迅速做出反应, 并在脑海中重现这些信息, 这不仅与人脑的巨大信息储存能力有关, 还说明人脑具有较强的特征提取能力。人工神经网络虽然是人脑的简单模拟和抽象, 但具有许多与人脑相似的信息处理能力, 自然也具有较强的数据压缩能力, 一些神经网络模型能直接提供数据压缩就是一个很好的例子。

由于现实图像内容变化的随机性, 对图像的分割以及平稳区域与非平稳区域的数学描述还没有找到一个有效的手段和方法, 试图用一种图像模型来描述自然界千奇百怪的图像是不现实的, 而人工神经网络在解决类似的黑箱上特别有效, 故可以用神经学习图像中规律性的东西, 通过神经网络自适应机制, 如结构自适应、学习率参数的变化和连接权值的变化等进行调整。因此, 可以利用神经网络的特点对图像信息进行有效的分解、表征和编码, 从而取得传统方法无法比拟的

结果。这就是将人工神经网络用于图像压缩的基本思想和出发点。

具体来讲, 与传统的图像压缩方法相比, 人工神经网络具有如下一些优势^[12]:

(1) 图像信号的正交变换中, 如果所选的基向量与图像信号的协方差矩阵的特征向量接近, 则变换域内图像信号的相关性将明显下降, 能量相对集中, 就能使图像信号的带宽得到较大压缩, 此时的变换比较接近最佳线性变换(KLT)。对于随机性很强的图像信号来说, 很难找到一种与不同统计特性的图像信号完全匹配的变换, 因此变换矩阵中基向量的选择不是固定的, 这就给最佳变换编码的实现带来了困难, 而神经网络的强映射力和非线性特性, 使它可以学习具有相当接近输入信号特征空间基的能力, 因此用来解决最佳变换的实现是很有效的;

(2) 神经网络中及其丰富的训练算法为设计高效的图像压缩编码系统提供了新的途径;

(3) 大多数人工神经网络都具有相当强的模式识别与模式分类能力, 这给图像编码方案中模式分类问题的解决提供了一个强有力的工具;

(4) 神经网络有较强的容错性和联想记忆功能, 任何局部的损坏不会影响整体结果, 这一特性有助于对有噪图像的数据压缩及对压缩后信息不全图像的恢复;

(5) 神经网络的大规模并行处理能力及分布式结构, 为神经网络图像编码的实时实现创造了条件, 这也是将神经网络用于图像编码的优势所在。

1.3.2 基于人工神经网络的图像压缩编码方法分类

目前, 将人工神经网络理论与技术引入图像编码领域的研究工作十分活跃, 发展相当快, 基于人工神经网络模型的图像编码方法已涉足图像编码研究的很多方面, 所使用的神经网络模型已有近十种, 对现有的神经网络图像编码方法进行归纳、总结, 有助于了解神经网络方法的发展方向, 使已取得的成果系统化, 使尚未解决的问题明确化。

不少神经网络模型都有相当强的数据压缩能力, 当然, 有些神经网络模型不能提供直接的数据压缩, 而是间接参与数据压缩。如果以用于图像编码的神经网络模型为主线, 对现有神经网络图像编码方法进行分类, 一方面可了解哪些神经网络模型具有压缩能力, 从而进一步挖掘潜力, 另一方面可了解神经网络与图像压缩技术结合的途径, 从而探讨其它模型的压缩能力, 建立适合数据压缩的新的模型, 在进行归类的过程中, 将那些常用的或者重要的神经网络模型和学习算法分别作为一个独立的类别, 而将那些很少使用或新近提出的神经网络模型划入其它类别, 按此原则, 目前用于图像编码的神经网络模型和学习算法主要有以下几类:

(1) 多层前馈神经网络, 其学习算法为 BP 算法, 所以又叫 BP 网络;

(2) Kohonen 自组织神经网络, 包括频率敏感竞争学习(FSCL)网络, 其学习算法

为自组织特征映射(SOFM)算法;

(3) Hpfield 神经网络;

(4) 模拟退火(SA)学习算法;

(5) 混合神经网络模型;

(6) 其它神经网络模型, 包括 CPN, 函数链神经网络, Sophia 联想神经网络(SANNET), 改进的 Hebbian 学习规则的系列应用 (SAMH)等。

同样, 按神经网络的应用领域来分, 大致可分为以下几个方面: (1) 预测编码; (2) 变换编码; (3) 分块截尾编码与平面拟合编码; (4) 矢量量化编码; (5) 小波编码; (6) 混合编码。

1.3.3 人工神经网络在图像压缩中的应用综述

虽然在 70 年代, 神经网络的发展一度陷入了低潮, 但是进入 80 年代以后, 一些学者经过十多年的理论研究, 在人工神经网络理论的一系列问题上取得了重大突破。随后人工神经网络的理论研究就进入了一个崭新的突飞猛进的时代。人工神经网络发展到现在, 迄今已发表的模型已达数百种之多。其中误差方向传播前馈网络(简称 BP 网络)、自组织特征映射神经网络(简称 SOFM 网络)、Hopfield 网络是目前最有代表性的三种网络^[51,52,53]。这三种网络在图像压缩中的应用最广泛, 因此下面重点叙述它们在图像压缩中的应用。

(1) BP 神经网络在图像压缩中的应用

BP 网络是目前最为常用的一种神经网络模型, 它可以直接提供数据压缩能力。最典型的例子是一种三层对称的 BP 网络, 包括输入层、隐含层和输出层, 隐含层的节点数要少于输入节点数, 输入节点数与输出节点数相同, 整个网络结构是完全对称的。学习时, 图像数据既送到输入层又送到输出层作为教师信号, 所使用的学习算法为 BP 算法。网络训练好以后, 输入层到隐含层为网络的编码过程, 对图像数据进行线性或者非线性变换, 从隐含层到输出层为网络的解码过程, 对经过压缩后的变换系数进行线性或非线性反变换, 恢复图像的原始数据。这类方法称为结构压缩法。

N.Sonehara 等人 1989 年探讨了三层前馈神经网络的通用性与训练图像数目以及迭代次数的关系, 还探讨了隐节点输出值量化和初始权值的选择对重建图像质量的影响, 为了控制网络规模, 将图像分成 8×8 的子块, 每一子块分别送到相应的子网络进行并行处理, 因此学习速度相当快, 每学习一幅图像仅一秒钟。1990 年, Z.He 与 H.Li 将多层前馈神经网络用于图像非线性预测编码^[16], 结果表明: 神经网络实现的非线性预测器优于线性预测器, 网络的抗噪性强, 通用性好。随后, S.A.Dianat 与张伟等人进行了类似的研究, 得出了相同的结论^[17,18]。

G.W.Cottrell 与 N.Sonehara 等人^[19,20]提出的三层神经网络虽然可以直接提供数

据压缩,但通用性较差,对非训练图像,编码质量显著下降,边缘失真很大,训练图像的编码质量也不尽如人意。为此,不少学者进行了进一步的研究,提出了许多改进方案^[21-26],其中最引人注目的是1991年S.Maris等人提出的一种改进结构的图像压缩方法^[23],根据图像块的活性参数,将它们分成六类,每一类送到相应的三层BP网络进行训练,不同的BP网络,根据图像块的活动特性取不同的隐层节点数。对训练外的图像“Lena”获得峰值信噪比(*PSNR*)为258dB,比特率为0.38bpp的压缩效果,重建图像的主观质量有较大提高,边缘与细节保持良好。

在上述神经网络图像压缩系统中,采用的均是三层线性或非线性神经网络。M.Arozullah等人提出了一种对称结构的五层神经网络模型^[27],采用扩展的BP嵌套训练算法进行学习,压缩比可达到64:1。国内的张秀明等人也对五层网络模型的图像压缩进行了有意义的探讨^[28],并就如何提高网络的压缩率和通用性提出了一些新的见解。

BP网络除了映射能力强以外,还具有较强的模式分类能力。F.Mekuria等人利用感知器模型设计了一种快速码书搜索算法^[29],这种算法计算量小于全搜索算法与树搜索算法,所需存储量也小于树搜索算法。

虽然BP网络训练时间很长,但学习后在线运算量却较小,并且具有并行计算结构,因此其实用性主要决定于网络的概括能力、压缩能力以及重建原始信息的能力,如用BP网络直接进行数据压缩,所取得的压缩比越高,网络通用性就越差,信息失真也大,因此其压缩能力是很有限的。

(2) Kohonen 自组织神经网络在图像压缩中的应用

Kohonen 自组织神经网络是一个两层结构的网络,采用SOFM学习算法,输出节点在平面上是按顺序排列的,根据输出节点对输入模式的响应,调整输出响应节点邻域内所有节点与输入节点之间的连接权值,这种调整是自组织完成的,Kohonen 自组织神经网络具有较好的拓扑聚类特性,对相近的输入模式,输出响应节点也是拓扑意义上相邻的,因此,网络输出节点的分布反映了输入模式的统计特征。

N.M.Naarabadi 与 Y.Feng 最早将SOFM算法引入矢量量化器的码书设计^[30],对 512×512 尺寸的8bpp图像进行矢量量化编码,编码图像比特率为2.15bpp。1989年,C.N.Manikopoulus等人在运动图像的编码中^[31],对SOFM算法作了自适应修正,以适应运动和背景的变化。在模拟实验中,对20帧 112×96 的图像,获得编码图像峰值信噪比为36-37dB,比特率为0.5bpp的压缩效果。1990年,K.K.Truong和R.M.Mersereau用SOFM算法实现了超立方体结构码书的设计^[32],针对算法的复杂性提出了一种码书的快速抽样搜索算法,与LBG算法的比较实验说明,SOFM算法具有更优越的性能。A.K.Krishnamurthy等人也对SOFM算法和FSCL算法进

行了研究^[33], 对 500×482 尺寸的 8bpp 图像进行矢量量化编码, 在保证一定图像质量的情况下, 编码图像比特率为 1bpp, 与此同时, T.C.Lee 和 A.M.Pererson 提出了一种 SPAN 神经网络^[34], 这种网络根据图像信源的统计特性来调整结构, 码字的搜索可以用快速算法实现, 用 SPAN 设计的码书, 使用路径编码方法, 其性能明显优于 LBG 算法, 值得一提的是, W.C.Fang 等人已将 S.C.Abalt 提出的 FSCL 网络用于图像的实时自适应矢量量化编码^[35]。

此外, 许多学者还对基于神经网络的图像矢量量化编码进行了相当广泛的研究^[36,37], 得出了许多有意义的结论, 但还有一些问题未能解决, 如矢量量化编码的重建图像与算法的时间复杂度以及压缩比之间的矛盾, 这些是有待于我们去解决的问题。

Kohonen 自组织神经网络是一种具有高度自适应性、自组织性和并行计算结构的网络, 特别适合于特征提取、模式分类等应用, 它与矢量量化技术的结合是神经网络图像编码这个新的研究方向中成功的典范。

目前将神经网络理论引入图像编码的某些领域的研究工作进展顺利, 成果屡有报道, 但离人们对这种图像编码新方法的期望还相差甚远, 可以说基于神经网络的图像编码方法的研究仍处于一个初级阶段, 还未取得重大的突破性进展。

(3) Hopfield 网络在图像压缩中的应用

Hopfield 神经网络是一种对称的、无自反馈的互连网络, 它具有非线性动力学特征, 可以用 Lyapunov 能量函数来描述, 网络的工作过程也就是能量函数趋于某一局部极小点的动态演化过程, 当且仅当网络状态不随时间变化时, 网络处于一个能量极小点。基于 Hopfield 网络的图像编码方法正是利用网络的这一特性, 利用所要解决的优化问题与网络的能量函数相关性, 从而确定神经元间的连接权值与神经元的偏置输入, 网络最终停留的平衡状态也就是所求问题的解。因此, 这类方法称为能量函数法。

L.O.Chua 和 T.Lin 最早将 Hopfield 网络引入图像编码领域^[42], 他们将变换编码中图像的正交变换、变换系数的量化以及编码转化为最优化问题, 构造了一个 Hopfield 网络进行求解, 并给出了神经网络算法的硬件实现电路。

1991 年, A.Tabatabai 和 T.P.Troudet 采用 Hopfield 神经网络实现了灰度与二值混合图像的分割^[43], 进行了图像压缩实验, 取得了 4 到 8 倍的压缩比。他们还使用 VLSI 技术硬件实现自适应神经网络, 实时分割了 16×16 的图像块。G.Qiu 等人于 1991 年用 Hopfield 神经网络实现了 BTC^[44], 在相同的压缩比下, 重建图像质量好于 BTC 及其改进算法。M.N.Pour 等人用 Hopfield 网络实现矢量量化编码^[45], 网络所包含的神经元数等于码书中的码字数目, 通过合理地选择网络参数, 编码失真可接近最小均方误差。

清华大学王卫等人于 1993 年提出了一种非完全 DCT 逆矩阵的神经网络方法^[46], 将它用于 DCT 编码图像的重建, 由于所建网络存在自反馈, 对其迭代规则进行了修改。另外, 针对 Hopfield 神经网络存在局部极小问题, 提出了一种扰动算法, 使网络的迭代避开局部极小点, 逼近全局最小点。实验表明, 该方法比 N.Sonehara 等人的方法^[20]获得的图像信噪比高 5-6dB。同年, 他们用上述改进的 Hopfield 网络模型求解平面拟合中的待定系数^[47], 性能优于传统的最小二乘法, 在压缩比略有提高的情况下, 重建图像质量改善约 1dB。

Hopfield 神经网络在解决某些优化问题时比传统算法具有更优越的性能, 但在实际应用中, 需要考虑其计算复杂度问题, 特别是对异步计算, 网络失去并行计算优势, 运算量随网络规模的增大急剧增加。此外, 网络运算结果与初始值的选取和动态演化过程密切相关。

1.4 基于人工神经网络的图像压缩的可行性分析

自从神经网络用于图像压缩领域以来, 这方面的论述已向人们展示了其发展潜力, 成为图像压缩领域的一个新兴研究方向。为了建立神经网络与图像压缩相结合的理论体系, 需要探索神经网络用于图像压缩的机理。正是由于这些机理的存在, 构成了人工神经网络与图像压缩技术结合的纽带。主要体现在以下方面:

(1) 二者本质同构

人脑对视觉感观传来的大量图像信息能迅速作出反应并在脑海中重现这些信息, 不仅与人脑的巨大信息存储能力有关, 还说明人脑具有较强的特征提取功能, 即数据压缩能力。人工神经网络虽然只是人脑的简单模拟与抽象, 但具有很多与人脑相似的信息处理能力, 自然也具有较强的数据压缩能力。神经网络的模式识别能力可解决图像编码方案中模式分类问题。编码问题可归纳为映射和优化问题。另外, 神经网络将促进图像编码向智能化和知识化的转化。神经网络较强的容错能力和联想记忆功能, 有助于对噪声图像的数据及对压缩后信息不完全图像的恢复。

(2) 神经网络训练学习与图像压缩的自适应性

图像信息有随机性和规律性两大特点, 可利用神经网络学习图像中规律性信息, 利用神经网络的自适应机制处理图像中随机性信息。因图像信号的随机性, 很难找到一种与不同统计特性的图像信号完全适配的变换实现最佳变换编码。而神经网络具有较强映射能力和非线性特性, 具备学习接近输入信号特征空间基的能力。由于神经网络利用例子进行训练, 因此在处理新数据时继续训练保证神经网络可以适应输入数据的改变。神经网络中及其丰富的训练方法为设计高效的图像压缩编码提供了新的途径。由于大多数神经网络的训练算法都是自适应的, 因

此可以用它们来设计自适应的图像压缩编码系统。

(3) 神经网络的并行结构和图像压缩的实时性

高度并行结构为编码的实时性提供了可能。神经网络的大规模并行处理能力是实现图像压缩编码的有利条件,神经网络的并行性打破了串行机制性能带来的瓶颈问题。

因此,人工神经网络用于图像压缩编码的研究试图模仿人类视觉系统的某些局部的初级功能,并利用神经网络巨大的并行分布信息处理能力,以实现快速经济的图像压缩编码。

1.5 本文的研究内容

本课题从学科发展史研究的角度,通过对人工神经网络和图像压缩这两个不同领域研究史与发展现状的分析最后切入到这一交叉学科研究课题的发展历程及研究前景。对 BP 算法及其改进方法作深入研究,并进行大量实验,总结出一种快速且压缩比高的 BP 网络图像压缩方法;另一方面,对各种神经网络矢量量化方法作深入的研究,特别用大量实验来验证自组织特征映射网络矢量量化方法的可行性;最后分别从压缩系统体系结构和压缩算法的角度将 Hopfield 网络边缘检测结果与自组织特征映射网络矢量量化方法相结合建立一个基于边缘保持的神经网络图像压缩系统,要求达到泛化能力强、系统稳定、重建图像边缘清晰而且以期获得高压缩比。这些就是本课题的研究内容。

全文共分六章,其具体内容安排如下:

第一章 绪论,首先概述了图像压缩的目的和意义,在此基础上介绍了传统的图像压缩技术和新型的图像压缩技术,特别介绍了新型图像压缩技术中的神经网络图像压缩技术以及综述了神经网络在图像压缩编码中的应用,并且专门分析了用神经网络实现图像压缩的优势以及可行性,最后对本文要做的工作进行了介绍。

第二章 系统地研究了神经网络的理论基础及其发展历史,主要从人工神经元模型和网络结构、神经网络的学习规则以及神经网络的分类来分析和探讨神经网络的有关基础知识,再者从人工神经网络的发展历程的角度即纵向分析人工神经网络的特点及应用,这些都为后面几章中人工神经网络在图像压缩和图像边缘检测中的实际应用打下坚实的基础。

第三章 基于 BP 网络的图像压缩方法的实现,从 BP 算法入手,研究了 BP 算法实现数据压缩的原理,着重分析 BP 算法在图像压缩中的应用原理及其关键技术,最后分别用单个 BP 网络和多级 BP 网络实现了图像压缩,并给出了实验仿真结果,并对其进行分析。

第四章 基于自组织特征映射网络(SOFM)的图像压缩方法的实现,类似于

第三章,首先研究 SOFM 网络的算法以及结构,然后介绍了矢量量化的有关理论,并在此基础上分析了 SOFM 网络在矢量量化中的应用及其关键技术,最后用 SOFM 网络实现矢量量化,从而实现图像压缩,并系统地分析各种参数对重建图像性能的影响。

第五章 基于 Hopfield 网络的图像边缘检测以及边缘保持的 SOFM 图像压缩,本章在第四章的基础上提出新的图像压缩方法,首先利用 Hopfield 网络实现了图像的边缘检测,然后利用检测结果计算原始图像的统计特征参数,并且运用这组参数去改进 SOFM 算法,从而实现边缘保持的 SOFM 图像压缩方法。最后给出实验仿真结果并分析。

第六章 总结全文,指出文章的创新点和研究结果,并提出了后续展望。

2 人工神经网络发展史及其基础理论研究

人工神经网络 (Artificial Neural Network, ANN), 是人们在模仿人脑处理问题的过程中发展起来的一种新型智能信息处理理论。它可以定义为: 由一组大规模并行、分布式处理机构成的能存储并使用知识的网络。它通过大量的称为神经元的简单处理单元构成非线性动力学系统, 对人脑的形象思维、联想记忆等进行模拟和抽象, 实现与人脑相似的学习、识别、记忆等信息处理能力。

2.1 人工神经网络发展历史回顾^[57, 58]

人工神经网络的研究始于 40 年代, 半个世纪以来, 经历了兴起、高潮与萧条、高潮及稳步发展的曲折道路。

1943 年, 心理学家 W.S.McCulloch 和数学家 W.Pitts 合作, 从人脑信息处理观点出发, 第一次采用数理模型的方法研究了脑细胞的动作和结构以及生物神经元的一些基本生理特性, 提出了第一个神经计算模型, 即神经元的阈值元件模型, 简称 MP 模型。这一模型为计算神经行为的某些方面提供了可行性, 开创了人工神经网络的研究。

1949 年, 神经生物学家 D.O.Hebb 在其论著 *The Organization of Behavior* 中对脑神经细胞的学习与条件反射提出了触突联系可变的假设, 即 Hebb 学习规则, 其基本思想是: 当两个细胞相互连接的神经元同时兴奋时, 则它们之间的权值就得到加强, 这一学习规则为神经网络的学习算法奠定了基础。

1958 年, 计算机科学家 Rosenblatt 基于 MP 模型, 增加了学习机制, 提出了著名的感知器 (Perception) 模型。他证明了两层感知器能够将线性可分的输入分为两类。他的模型包含了现代计算机的一些原理, 是第一个完整的人工神经网络, 并首次把神经网络研究付诸工程实现。

1960 年, B.Windrow 和 E.Hoff 提出了自适应线性元件 (Adaptive Linear Element, 简称 Adaline) 网络模型, 这是一种连续取值的线性网络, 可用于自适应滤波、预测和模式识别。这也是第一个对实际问题起作用的人工神经网络。至此, 人工神经网络的研究工作进入了第一个高潮。

值得一提的是, 我国中科院生物物理所在 1995 年提出用矩阵法描述一些神经网络模型。他们重点研究视觉系统的信息传递过程和加工的机理以及建立有关的数学模型。

1969 年, 美国著名人工智能学者 M.Minsky 和 S.Papert 编写了影响很大的 *Perception* 一书, 从理论上证明了单层感知机的能力有限, 比如不能解决异或问题,

而且他们推测多层感知器的能力也不过如此。他们的分析使很多学者感到前途渺茫而纷纷改行，原先参与研究的实验室纷纷退出。在这之后近 10 年，神经网络研究进入了一个缓慢发展的萧条期。这期间，美国学者 S.A.Grossberg 创建了自适应共振理论（ART），这是感知器较完善的模型，即 supervised 学习方式，它有两种结构 ART1 和 ART2，能够识别或分类任意多个复杂的二元输入图像，其学习过程有自组织和自稳定的特征；芬兰学者 T.Kohonen 提出了自组织映射理论，反映了脑神经细胞的自组织特征、记忆方式以及神经学习兴奋刺激的规律；日本学者 K.Fukushima 提出了认知机模型；ShunIchimari 则致力于神经网络有关数学理论的研究等，这些研究成果对以后的神经网络的发展产生了重要影响。

1982 年和 1984 年美国生物物理学家 J.J.Hopfield 在美国科学院院刊先后发表的两篇文章，有力地推动了神经网络的研究，引起了神经网络的又一次高潮。1982 年，他提出了一个新的神经网络模型——Hopfield 网络模型。他在这种网络模型的研究中，首先引入了网络能量函数的概念，并给出了网络稳定性的判定依据。1984 年，他又提出了网络模型实现的电子线路，为神经网络的工程实现指明了方向。他的研究成果开拓了神经网络用于联想记忆的优化计算的新途径，并为神经计算机研究奠定了基础。

1984 年，Hinton 等人将模拟退火算法引入到神经网络中，提出了 Boltzmann 机网络模型，BM 网络算法为神经网络优化计算提供了一个有效的方法。

1986 年，D.E.Rumelhart 和 J.Lmcclelland 合著的 *Parallel Distributed Processing: Exploration in the Microstructures of Cognition* 两卷书出版，对神经网络的发展起了极大的推动作用。它包括了物理学、数学、分子生物学、神经科学、心理学和计算机科学等许多相关学科的著名学者从不同研究方向或领域取得的成果。尤其是 Rumelhart 提出了多层网络 Back-Propagation 法或称 Error-Propagation 法，这就是后来著名的误差反向传播（BP）算法，受到许多学者的重视，成为至今为止影响很大的一种网络学习方法。

1987 年美国神经网络计算机专家 R.Hecht-Nielsen 提出了对向传播神经网络，该网络具有分类灵活、算法简单的优点，可用于模式分类、函数逼近、统计分析和数据压缩等领域。

1988 年 L.Ochua 等人提出了细胞神经网络模型，它在视觉初级加工上得到了广泛应用。

为适应人工神经网络的发展，1987 年在圣地雅哥召开了首届国际神经网络大会，国际神经网络联合会 (INNS) 宣告成立。1988 年 1 月，INSS 创办的刊物 *Journal Neural Networks* 问世，1990 年 3 月 *IEEE Transaction on Neural Networks* 问世，同期还诞生出十几种国际著名的神经网络学术刊物。这些都为神经网络的研究和发

展起了推波助澜的作用，自此人工神经网络步入了稳步发展的时期。

我国学术界大约在 80 年代中期关注神经网络领域，系统科学家钱学森在 1986 年主编的论文集《关于思维科学》中编入了三篇神经网络方面的论文。这本书引起了国内学术界有关人士的极大反响。一些科学家开始投身到人工神经网络的研究中来，如中科院生物物理所科学家汪云九、姚国正和齐翔林等。北京大学非线性研究中心在 1988 年 9 月发起举办了 Beijing International Workshop on Neural Networks: Learning and Recognition, a Modern Approach。1990 年 12 月我国的八个学会联合在北京召开了神经网络首届学术大会。我国“863”高技术研究计划和“攀登”计划于 1990 年批准了人工神经网络的 3 项课题，自然科学基金和国防科技预研基地也都把神经网络的研究列入了选题指南。许多全国性学术年会和一些学术刊物把神经网络理论及应用方面的论文列为重点。

90 年代初，诺贝尔获得者 Edelman 提出了 Darwinism 模型，建立了神经网络系统理论。同年，Aihara 等在前人推导和实验的基础上，给出了一个混沌神经元模型，该模型可用于联想记忆，并已成为一种经典的混沌神经网络模型。Wunsch 在 900SA 年会上提出了一种 AnnualMeeting，用光电执行 ART，学习过程有自适应滤波和推理功能，具有快速和稳定的学习特点。1991 年，Hertz 探讨了神经计算理论，对神经网络的计算复杂性分析具有重要意义。Inoue 等提出用耦合的混沌振荡子作为某个神经元，构造混沌神经网络模型，为它的广泛应用前景指明了道路。1992 年，Holland 用模拟生物进化的方式提出了遗传算法，用来求解复杂化问题。1993 年，方建安等采用遗传算法学习，研究神经网络控制器获得了一些结果。1994 年 Angeline 等在前人进化策略理论的基础上，提出了一种进化算法来建立反馈神经网络，成功地应用到模式识别，自动控制等方面。廖晓昕对细胞神经网络建立了新的数学理论和方法，得到了一系列结果。HayashiY 根据动物大脑中出现的振荡现象，提出了振荡神经网络。1995 年，Mitra 把人工神经网络理论与模糊逻辑理论、生物细胞学说以及概率论相集合提出了模糊神经网络，使得神经网络的研究取得了突破性进展。Jenkins 等人研究光学神经网络，建立了光学二维并行互连与电子学混合的光学神经网络，它能避免网络陷入局部极小值，并最后可达到或接近最理想的解。SoleRV 等提出流体神经网络，用来研究昆虫社会，机器人肌体免疫系统，启发人们用混沌理论分析社会大系统。1996 年，ShuaiJW 等模拟人脑的自发展行为，在讨论混沌神经网络的基础上提出了自发展神经网络。1997 年和 1998 年董聪等创立和完善了广义遗传算法，解决了多层前向网络的最简拓扑构造问题和全局最优逼近问题。

随着理论工作的发展，神经网络的应用研究也取得了突破性进展，涉及面非常广泛，就应用的技术领域而言就有计算机视觉，语音的识别、理解与合成，优

化计算, 智能控制及复杂系统分析, 模式识别, 神经计算机研制, 知识推理专家系统与人工智能。涉及的学科有神经生理学、认识科学、数理科学、心理学、信息科学、微电子学、光学、动力学、生物电子学等。美国、日本等国在神经网络计算机硬件实现的开发方面也取得了显著的成果, 并逐步形成产品。

2.2 人工神经元模型与网络结构^[8]

在图像压缩中用到的网络均使用多输入神经元模型, 因此本文不介绍单输入网络结构, 直接从多输入神经元模型入手介绍人工神经元模型及其网络结构。

2.2.1 多输入神经元

通常, 一个神经元有不只一个输入。具有 R 个输入的神经元如图 2.1 (a) 所示。其输入 p_1, p_2, \dots, p_R 分别对应权值矩阵 W 的元素 $w_{1,1}, w_{1,2}, \dots, w_{1,R}$ 。

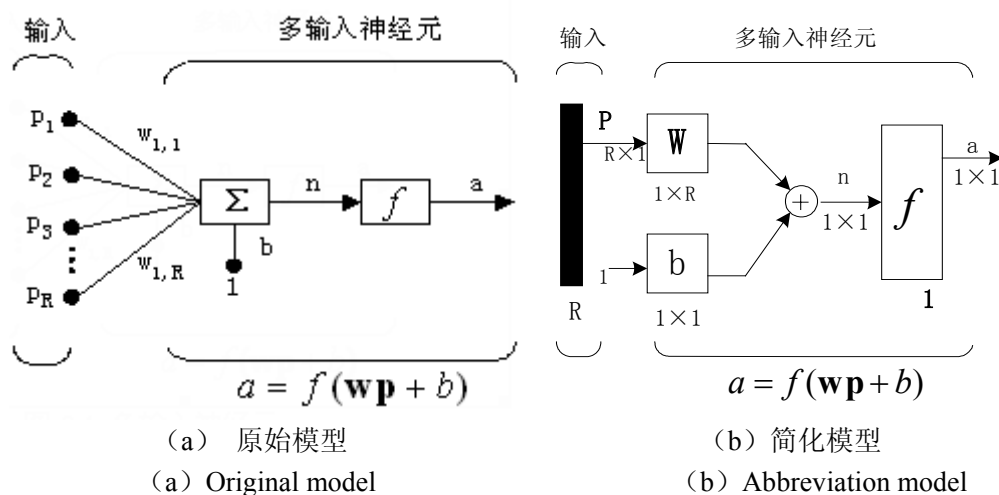


图 2.1 多输入神经元

Fig2.1 The neuron with multi-input

该神经元有一个阈值 b , 它与所有输入的加权和累加, 从而形成净输入 n :

$$n = w_{1,1}p_1 + w_{1,2}p_2 + \Lambda + w_{1,R}p_R + b \quad (2.1)$$

这个表达式也可以写成矩阵形式:

$$n = \mathbf{W}\mathbf{p} + b \quad (2.2)$$

其中单个神经元的权值矩阵 \mathbf{W} 只有一行元素。

神经元的输出可以写成:

$$a = f(\mathbf{W}\mathbf{p} + b) \quad (2.3)$$

依据不同的目的可以选择不同的传输函数 f 。

用简化符号所表示的多输入神经元, 如图 2.1 (b) 所示。图中, 左边垂直的实心条表示输入向量 \mathbf{p} , \mathbf{p} 下面的变量 $R \times 1$ 表示 \mathbf{p} 的维数, 也即输入是由 R 个元素组成的一维向量。这些输入被送入权值矩阵 \mathbf{W} , \mathbf{W} 一行 R 列。常量 1 则作为输

入与标量阈值 b 相乘。传输函数 f 的净输入是 n ，它是阈值 b 与积 \mathbf{Wp} 的和。在这种情况下，神经元的输出 a 是一个标量。如果网络有多个神经元，那么网络输出就可能是一个向量。网络的输入是由问题的外部描述决定的。

2.2.2 基本网络结构

一般来说，有多个输入的单个神经元并不能满足实际应用的要求。在实际应用中需要多个并行操作的神经元。这些可以并行操作的神经元组成的集合称为“层”。

(1) 神经元的层

图 2.2 是由 S 个神经元组成的单层网络。 R 个输入神经元的每一个均与每个神经元相连，权值矩阵有 S 行。该神经网络层包括权值矩阵、累加器、阈值向量 \mathbf{b} 、传输函数框和输出向量 \mathbf{a} 。输入向量 \mathbf{p} 的每个元素均通过权值矩阵 \mathbf{W} 和每个神经元相连。每个神经元有一个阈值 b_i 、一个累加器、一个传输函数 f 和一个输出 a_i 。将所有神经元的输出结合在一起，可以得到一个输出向量 \mathbf{a} 。通常，每层的输入个数并不等于该层中神经元的数目（即有 $R \neq S$ ）。同一层神经元也不必有相同的传输函数。

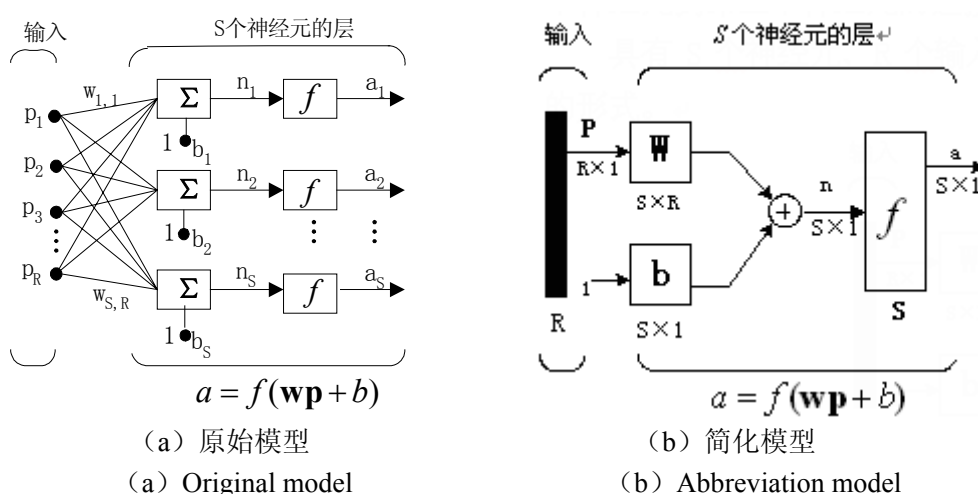


图 2.2 S 个神经元组成的层

Fig2.2 The layer composed of S neurons

输入向量通过如下权值矩阵 \mathbf{W} 进入网络：

$$\mathbf{W} = \begin{bmatrix} w_{1,1} & w_{1,2} & \Lambda & w_{1,R} \\ w_{2,1} & w_{2,2} & \Lambda & w_{2,R} \\ \text{M} & \text{M} & \text{M} & \text{M} \\ w_{S,1} & w_{S,2} & \Lambda & w_{S,R} \end{bmatrix} \quad (2.4)$$

同样，矩阵 \mathbf{W} 中元素的行下标代表该权值相应连接输出的目的神经元，而列下标代表该权值相应连接的输入源神经元。例如， $w_{3,2}$ 的下标表示该元素是从第二

个神经元到第三个神经元的连接的权值。

具有 S 个神经元、 R 个输入的单层网络也能用简化的符号表示为如图 2.2 (b) 的形式。图中 \mathbf{P} 是长度为 R 的向量， \mathbf{W} 是一个 $S \times R$ 矩阵， \mathbf{a} 和 \mathbf{b} 是长度为 S 的向量。如前所述，该层包括权值矩阵，加操作和乘操作，阈值向量 \mathbf{b} ，传输函数框和输出向量。

(2) 多层神经元及其网络结构

多层神经元就是具有多个如前所定义的神元层的网络结构。每层都有自己的权值矩阵 \mathbf{W} ，阈值向量 \mathbf{b} ，净输入向量 \mathbf{n} 和一个输出向量 \mathbf{a} 。用上标来标注这些层次，即每个变量都附加一个上标来表示其所处层次。这样，第一层的权值矩阵可以写为 \mathbf{W}^1 ，第二层的权值矩阵可以写为 \mathbf{W}^2 ，等等。

下面用简化方法表示一个三层网络，如图 2.3 所示。第一层有 R 个输入， S^1 个神经元，第二层有 S^2 个神经元。当然，不同层可以有不同的神经元数目。第一层和第二层的输出分别是第二层和第三层的输入。据此，可以将第二层看作是一个单层网络，它有 $R=S^1$ 个输入， $S=S^2$ 个神经元，和一个 $S^1 \times S^2$ 维的权值矩阵 \mathbf{W}^2 。第二层的输入是 \mathbf{a}^1 ，输出是 \mathbf{a}^2 。

如果多层神经元某层的输出是网络的输出，那么称该层为输出层，而其它层叫隐含层。对于 2.3 图中的网络，有一个输出层（第三层）和两个隐含层（第一层和第二层）。

多层网络的功能要比单层网络强大得多。比如，一个第一层具有 S 形传输函数，第二层具有线性传输函数的网络，经过训练可对大多数函数达到任意精度的逼近，而单层网络则不能做到这一点。

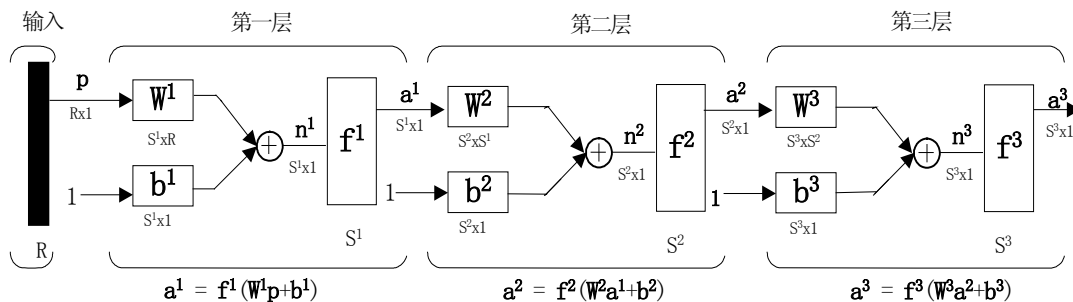


图 2.3 三层网络的简化表示

Fig2.3 Abbreviation notation of three layers neural network

由此可以看出，决定一个网络的神经元个数非常重要。网络的输入/输出神经元的数目是由问题外部描述定义的。所以，如果有 4 个外部变量作为网络的输入，那么网络就有 4 个输入量。同样，如果网络有 7 个输出，那么网络的输出层就应该有 7 个神经元。最后，输出信号所期望的特征有助于选择输出层的传输函数。

如果一个输出要么是-1，要么是+1，那么该输出神经元就可以用对称硬极限传输函数。所以，单层网络结构完全由问题描述决定，包括特定的输入/输出数目和输出信号的特征。

如果网络有两层以上的神经元时，确定各层神经元数目的关键在于外部问题并没有直接指明隐含层需要的神经元数目。实际上，精确预测隐含层所需要的神经元的数目至今任然存在一些在理论上还没有解决的问题。这个问题也一直是十分活跃的研究领域。

至于网络中的神经元层数，大多数实际的神经网络仅仅只有2到3层神经元，很少有4层或者更多层的。另外，是否使用阈值是可以选择的。阈值给网络提供了额外的变量，从而使得网络具有更强的能力，事实也的确是如此。

(3) 递归网络结构

递归网络是一个带反馈的网络，其部分输出连接到它的输入。这与前面的所讨论的没有反馈连接的严格前馈网络有很大不同。图2.4给出了一种类型的离散时间递归网络。

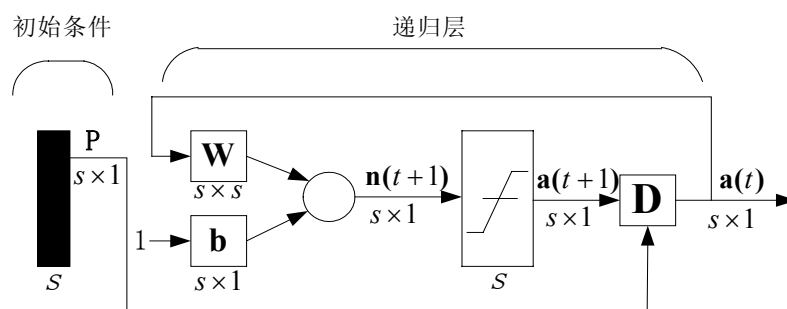


图 2.4 递归网络结构

Fig2.4 Structure of recursion neural network

在该网络中，向量 \mathbf{p} 给出了其初使条件（即 $\mathbf{a}(0) = \mathbf{p}$ ）。网络根据其前一次输出计算当前的输出：

$$\mathbf{a}(1) = \text{satlins}(\mathbf{W}\mathbf{a}(0) + \mathbf{b}), \quad \mathbf{a}(2) = \text{satlins}(\mathbf{W}\mathbf{a}(1) + \mathbf{b}), \quad \dots$$

$$\mathbf{a}(t+1) = \text{satlins}(\mathbf{W}\mathbf{a}(t) + \mathbf{b}), \quad \dots \quad (2.5)$$

递归网络比前馈网络在本质上具有更强的能力，它可以表现出时间性行为。

2.3 人工神经网络的分类^[8]

神经网络的结构是多种多样的，按照网络的拓扑结构一般可分为两种：前馈网络和反馈网络。

(1) 前馈网络

在前馈网络中，神经网络通常是分层的，信号从输入层连接到下一层的各节

点, 这里的下一层指所谓的中间层 (或隐含层), 中间层可能是一层或多层, 最后通过输出层节点得到输出。前馈网络的特点是: 神经元通过层与层相接, 同一层内互不连接, 也没有隔层的前馈连接, 每一节点只能前馈到下一层的所有节点。通常的前馈网络包括 MADLINE 网络、多层感知机网络(MLPN)、径向基函数网络(RBFN)等。前馈网络可以非常好地在输入输出之间形成一静态函数映射, 任意给定时刻的输出只是该时刻输入的函数。

(2) 反馈网络

一般来说, 凡包含反馈连接的网络, 均称为反馈网络, 也称为回归型网络。反馈连接就是输出通过连接权回送到同一层或前一层的输入。在反馈网络中, 以前的输出反馈到输入, 所以其输出不仅取决于当前的输入, 还取决于以前的输出。即反馈网络具有动态记忆的功能。反馈网络通常包括 Hopfield 网络、Boltamann 机、ART 网络等。Hamming 网络则是两种形式网络的合成。

2.4 人工神经网络的学习规则^[8]

所谓学习规则, 就是在网络训练过程中, 修改神经网络的权值和阈值的方法和过程 (也把这种过程称为训练算法)。学习规则的目的是为了训练网络来完成某些工作, 有很多类型的学习规则, 大致可以分为三大类:

(1) 有监督学习

有监督学习也称有导师学习, 网络待分类的模式类别属性已知。对应每次模式样本的输入, 网络输出端都有一个对应的目标输出信号与其属性相匹配。基于网络输出端目标信号与实际输出的某种目标函数准则, 通过不断调整网络的连接权值, 使得网络输出端的输出与目标输出的误差逐渐减小到预定的要求。

在有监督学习中, 学习规则由一组描述网络行为的实例集合 (训练集) 给出:

$$\{p_1, t_1\}, \{p_2, t_2\}, \Lambda \{p_Q, t_Q\} \quad (2.6)$$

其中, p_q 为网络的输入, t_q 为相应的正确的 (目标) 输出。当输入作用到网络时, 网络的实际输出与目标输出相比较, 然后学习规则调整网络的权值和阈值, 从而使网络的实际输出越来越接近网络的目标输出。

(2) 无监督学习

无监督学习又称无导师学习, 网络待分类的模式属性未知, 网络没有目标输出。网络结构和连接权值根据某种聚类法则, 调整网络的权值和阈值, 自动对周围环境的模式样本进行学习调整, 直到网络的结构和连接分布能合理地反映训练样本的统计分布, 这种功能特别适合矢量量化等应用问题中。

(3) 有监督和无监督混合学习

这种学习规则中, 网络待分类的模式类别属性已知。网络的内部结构和参数

按照无监督聚类方法学习，而网络输出层仍然有一个对应的目标输出信号。按照某种准则，通过不断调整隐含层与输出层的连接权值，使得网络输出层的输出与目标信号的误差逐渐减小到预定的要求。

在实际操作过程中，即使是无监督学习的网络，往往也需要人为选择控制参数。所以，从广义上来说，所有的学习方法都是有监督的学习。表 2.1 给出了几种学习规则的性能比较。

表 2.1 几种学习规则的性能比较

Table2.1 The comparison of performance of several learning rules

方 式 指 标	训练速度	模板属性	自适应性	实现目标	推广能力
有监督学习	慢	有	强	容易	较好
无监督学习	快	无	好	可变	较好
混合学习	较快	有或无	好	容易	好

2.5 本章小结

本章首先回顾了人工神经网络在国内外的的发展过程，纵向了解和认识人工神经网络的特点和应用，它一度成为数学界、神经计算以及人工智能领域最富挑战性和最引人入胜的研究热点，至今仍方兴未艾，这坚定了把它应用于实际工程中的信心；本章的另一个重点放在对人工神经网络的基础理论的研究上面，这方面的研究是本课题得以进行下去的基石，主要从人工神经网络的模型、网络结构、分类及其学习规则等方面展开讨论及深入研究，因此本章的内容是必不可少的。

3 基于 BP 网络的图像压缩

BP 网络是目前用途最为广泛的一种神经网络模型之一，它能够直接提供数据压缩能力。本章从探讨 BP 算法入手，认真分析利用 BP 网络实现数据压缩的原理，深入研究它在图像压缩中的应用及其关键技术，分别应用 BP 算法的各种学习规则来实现图像压缩，在这个基础上，尝试运用多级 BP 网络来实现图像压缩，从而达到更高的压缩比，这是一种新的尝试，也是本文的创新之一。

3.1 BP 算法研究

反向传播算法又称误差后向传播算法(Error Backpropagation Algorithm)，它是用来训练多层前馈网络的一种学习算法，是一种有监督的学习算法。通常称用误差反向传播算法训练的网络叫 BP 网络，其算法流程如图 3.1 所示。

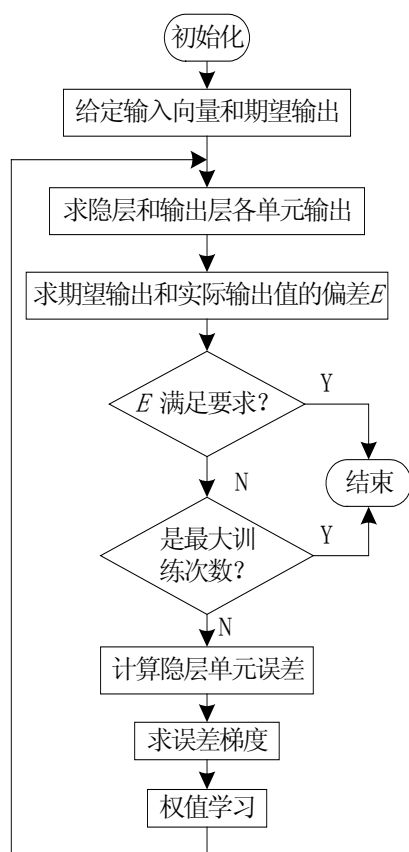


图 3.1 BP 算法流程

Fig3.1 The flow diagram of BP

误差反向传播算法的主要思想是把学习过程分为两个阶段：第一阶段（正向传播过程），给出输入信息通过输入层经隐含层逐层处理并计算每个单元的实际输出值；第二阶段（反向传播过程），若在输出层未能得到期望的输出值，则逐层递归地计算实际输出与期望输出之差值（即误差），以便根据此误差调节权值。具体地说，就是对每个权值计算出接收单元的误差值与发送单元的激活值的积。因为这个积和误差对权值的（负）微商成正比（又称梯度下降算法），把它称作权值误差微商。权值的实际改变可由权值误差微商一个模式一个模式地计算出来，即它们可以在这组模式集上进行累加。

误差反向传播算法的性能函数是均方误差。对单层的线性网络，误差是网络权值的显式线性函数，其相对于权值的导数较为容易求得。在具有非线性传输函数的多层网络中，网络权值和误差的关系就更为复杂。为了计算导数，需要使用微积分的链式法则^[8]。

3.1.1 BP 网络结构及其算法

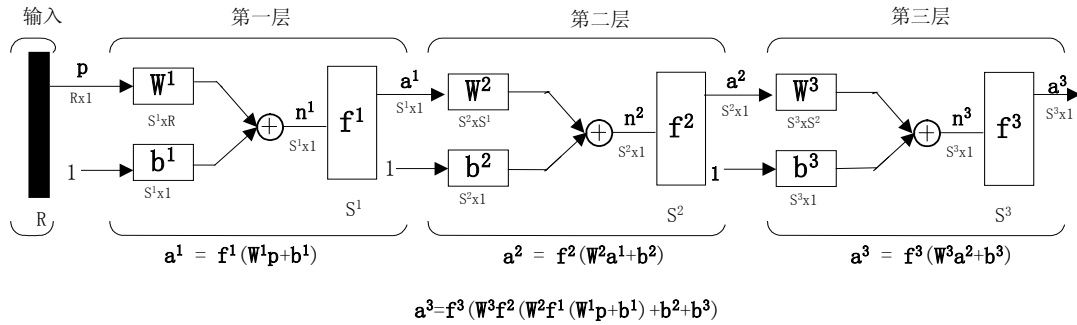


图 3.2 使用缩写符号的三层前馈网络

Fig3.2 Three layers feedforward neural network with abbreviation symbol

图 3.2 是使用缩写符号标记的三层神经网络。多层网络中某一层的输出成为下一层的输入，描述此操作的等式为：

$$\mathbf{a}^{m+1} = \mathbf{f}^{m+1}(\mathbf{W}^{m+1} \mathbf{a}^m + \mathbf{b}^{m+1}), \quad m = 0, 1, \dots, M-1 \quad (3.1)$$

这里， M 是网络的层数。第一层的神经元从外部接收输入：

$$\mathbf{a}^0 = \mathbf{p} \quad (3.2)$$

最后一层神经元的输出即是网络的输出：

$$\mathbf{a} = \mathbf{a}^M \quad (3.3)$$

3.1.2 性能函数

多层前馈网络的 BP 算法的性能函数是均方误差函数。算法的输入是一个网络正确行为的集合：

$$\{\mathbf{p}_1, \mathbf{t}_1\}, \{\mathbf{p}_2, \mathbf{t}_2\}, \dots, \{\mathbf{p}_q, \mathbf{t}_q\} \quad (3.4)$$

这里 \mathbf{p}_q 是网络的输入， \mathbf{t}_q 是对应的目标输出。每输入一个样本，便将网络输出与目标输出相比较。算法将调整网络参数以使均方误差最小化：

$$F(\mathbf{x}) = E[e^2] = E[(t - a)^2] \quad (3.5)$$

这里， \mathbf{x} 是网络权值和阈值向量。若网络有多个输出，则上式的一般形式为：

$$F(\mathbf{x}) = E[\mathbf{e}^T \mathbf{e}] = E[(\mathbf{t} - \mathbf{a})^T (\mathbf{t} - \mathbf{a})] \quad (3.6)$$

用 $\hat{F}(\mathbf{x})$ 来近似计算均方误差：

$$\hat{F}(\mathbf{x}) = (\mathbf{t}(k) - \mathbf{a}(k))^T (\mathbf{t}(k) - \mathbf{a}(k)) = \mathbf{e}^T(k) \mathbf{e}(k) \quad (3.7)$$

这里，均方误差的期望值被第 k 次迭代时的均方误差所代替。

近似均方误差的最速下降算法为：

$$w_{i,j}^m(k+1) = w_{i,j}^m(k) - \alpha \frac{\partial \hat{F}}{\partial w_{i,j}^m} \quad (3.8)$$

$$b_i^m(k+1) = b_i^m(k) - \alpha \frac{\partial \hat{F}}{\partial b_i^m} \quad (3.9)$$

这里， α 是学习速度。

下面将求取式(3.8)和式(3.9)中的偏导数。

3.1.3 偏导数的链法则

对单层线性网络 (ADALINE)，这些偏导数可以方便的求出，因为误差是网络权值的显式函数。对于多层网络，误差不是隐层中的权值的显式函数，因此这些偏导数求取就更难一些。因为误差是隐层中的权值的隐函数，所以就用微积分中的链式法则来计算偏导数。假设有一个函数 f ，它仅是变量 n 的显式函数，现在求 f 关于第三个变量 w 的导数，链法则为：

$$\frac{df(n(w))}{dw} = \frac{df(n)}{dn} \times \frac{dn(w)}{dw} \quad (3.10)$$

下面用此法则来求式 (3.8) 和式 (3.9) 中的偏导数：

$$\frac{\partial \hat{F}}{\partial w_{i,j}^m} = \frac{\partial \hat{F}}{\partial n_i^m} \times \frac{\partial n_i^m}{\partial w_{i,j}^m} \quad (3.11)$$

$$\frac{\partial \hat{F}}{\partial b_i^m} = \frac{\partial \hat{F}}{\partial n_i^m} \times \frac{\partial n_i^m}{\partial b_i^m} \quad (3.12)$$

式(3.11)和(3.12)的第二项均可容易地求出，因为 m 层的网络输入是那一层的权值和阈值的显式函数：

$$n_i^m = \sum_{j=1}^{s^{m-1}} w_{i,j}^m a_j^{m-1} + b_i^m \quad (3.13)$$

因此，

$$\frac{\partial n_i^m}{\partial w_{i,j}^m} = a_j^{m-1}, \quad \frac{\partial n_i^m}{\partial b_i^m} = 1 \quad (3.14)$$

若定义

$$s_i^m = \frac{\partial \hat{F}}{\partial w_{i,j}^m} \quad (3.15)$$

(\hat{F} 对 m 层的输入的第 i 个元素变化的敏感性)，则式 (3.11) 和 (3.12) 可简化为

$$\frac{\partial \hat{F}}{\partial w_{i,j}^m} = s_i^m a_j^{m-1} \quad (3.16)$$

$$\frac{\partial \hat{F}}{\partial b_i^m} = s_i^m \quad (3.17)$$

现在可以将近似最速下降法表示为：

$$w_{i,j}^m(k+1) = w_{i,j}^m(k) - \alpha s_i^m a_j^{m-1} \quad (3.18)$$

$$b_i^m(k+1) = b_i^m(k) - \alpha s_i^m \quad (3.19)$$

用矩阵形式表示，则为

$$\mathbf{W}^m(k+1) = \mathbf{W}_{i,j}^m(k) - \alpha \mathbf{s}^m (\mathbf{a}^{m-1})^T \quad (3.20)$$

$$\mathbf{b}^m(k+1) = \mathbf{b}^m(k) - \alpha \mathbf{s}^m \quad (3.21)$$

这里

$$\mathbf{s}^m \equiv \frac{\partial \hat{F}}{\partial \mathbf{n}^m} = \begin{bmatrix} \frac{\partial \hat{F}}{\partial n_1^m} \\ \frac{\partial \hat{F}}{\partial n_2^m} \\ \vdots \\ \frac{\partial \hat{F}}{\partial n_{s^m}^m} \end{bmatrix} \quad (3.22)$$

3.1.4 本文中用到的 BP 传输函数

(1) 非线性函数——对数-S 型函数

对数-S 型(logsig)传输函数如图 3.3 所示。

该函数的输入在 $(-\infty, +\infty)$ 之间取值，输出则在 0 到 1 之间，其数学表达式为：


$$a = \frac{1}{1 + e^{-n}} \quad (3.23)$$

从某种程度上可以说，正是由于对数-S 型函数是可微的，所以用于反传 (BP) 算法训练的多层网络才采用了该传输函数。

(2) 线性函数


线性传输函数（如图 3.4 所示）的表达式为：

$$a = n \quad (3.24)$$



$$a = \log \text{sig}(n)$$

图 3.3 对数-S 型函数
Fig3.3 Logarithm S-pattern function



$$a = n$$

图 3.4 线性函数
Fig3.4 Linear function

3.2 BP 网络图像压缩

3.2.1 基本原理

BP 网络是目前最为常见的一种网络模型，它可以直接提供数据压缩能力，见文献[48][49][50]。利用多层前馈网络的模式变换能力实现数据变换（编码）的基本思想是：把一组输入模式通过少量的隐含层单元映射到一组输出模式，并使输出模式尽可能等于输入模式。当隐含层的单元数比输入模式数少时，就意味着隐含层能更有效地表现输入模式，并把这种表现传送到输出层。在这个过程中，输入层和中间层的变换可以看成压缩编码的过程；而中间层和输出层的变换可以看成解码过程。图 3.5 给出了这一思想的简要说明。




图 3.5 用多层前馈神经网络实现数据压缩的基本思想

Fig3.5 The basic thought of data compression by multilayer neural networks

假设网络的输入层和输出层各由相同的 M 个神经元组成，隐含层的神经元数 K 比 M 小。在输入层和输出层提供同一学习模式（即教师模式为输入模式），网络通过学习后其隐含层应能对 M 个输入模式中的每一个给出不同的编码表示，这好比是大量的数据从较大的入口进入，然后强迫其通过细腰型的网络管道（如图 3.6 所示），并期望在该细腰处被压缩（编码），最后网络在出口处可由此编码恢复出与输入对应的输出结果。

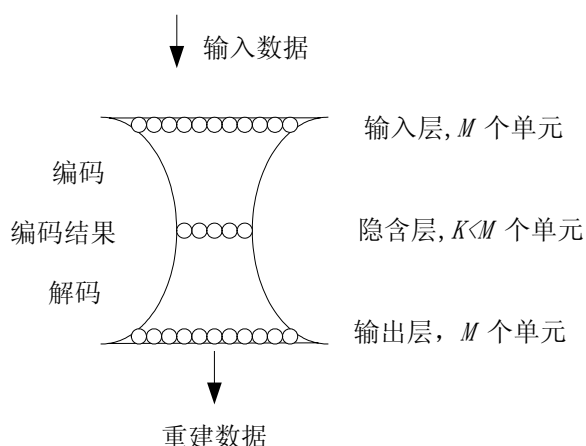


图 3.6 采用 BP 网络进行数据压缩

Fig3.6 The data compression by BP neural network

最简单的 BP 网络由一个输入层，一个隐含层和一个输出层构成。输入层和输出层均含有 $n \times n$ 个神经元，各神经元对应于 $n \times n$ 图像分块中的每一像素，隐含层神经元数的多少是根据压缩比的不同所决定的，其结构如图 3.7 所示。




图 3.7 用于图像压缩编码的 BP 网络

Fig3.7 The BP neural network in image compression coding

考虑用于学习的图像有 $N \times N$ 个像素点，各像素灰度值被量化为 m 比特(共 2^m 个可能的取值)。 2^m 个灰度按线性关系转化成 0 到 1 之间的数值作为网络的输入和期望输出（教师模式）。网络随机地抽取各 $n \times n$ 图像块（经过 $[0, +1]$ 区间的变换）作为学习模式，用 BP 算法学习。通过调整网络中神经元之间的连接权值，使训练集图像的重建误差 $E = \|f - g\|^2$ 的均值达到最小，训练好的网络就可以用来执行数据压缩的任务，隐含层神经元矢量（经过量化）便是数据压缩的结果，而输出神经元矢量便是重建的数据。实际上，这时的 BP 网络整个来看完成的是自联想学习。

3.2.2 计算模型

对应图 3.7 的计算模型如图 3.8 所示。




图 3.8 用于图像压缩的 BP 网络的计算模型

Fig3.8 The computation model of BP neural network in image compression

网络包括输入层、隐含层和输出层，隐含层的节点数少于输入节点数，输入节点数与输出节点数相同。学习时，图像数据既送到输入层又送到输出层作为教师信号，所使用的学习算法为 BP 算法。网络训练好以后，输入层到隐含层为网络的编码过程，从隐含层到输出层为网络的解码过程。

构造一个 $N-K-N$ 的三层 BP 网络，则输入层与隐含层之间的连接权值矩阵表示为： $\{w_{ji}: 1 \leq j \leq K, 1 \leq i \leq N\}$ ，隐含层第 j 个神经元的阈值表示为： $\{b_j: 1 \leq j \leq K\}$ ；同理，输出层和隐含层之间的连接权值矩阵可以表示为： $\{w'_{ij}: 1 \leq i \leq N, 1 \leq j \leq K\}$ ，输出层第 i 个神经元的阈值可以表示为： $\{b'_i: 1 \leq i \leq N\}$ 。通过不断训练网络，调整网络的权重，使得网络的输入与输出的均方差达到最小，最终将 N 维矢量压缩成 K 维矢量 ($K < N$)。根据图 3.8，隐含层第 j 个神经元的输出值为：

$$h_j = f^1\left(\sum_{i=1}^N w_{ji} x_i + b_j\right) \quad 1 \leq j \leq K \quad (3.25)$$

输出层的第 i 个神经元的输出可以描述为：

$$y_i = f^2\left(\sum_{j=1}^K w'_{ij} h_j + b'_i\right) \quad 1 \leq i \leq N \quad (3.26)$$

式中， f^1 和 f^2 分别是隐含层和输出层的传输函数， $x_i \in [0,1]$ ，它是灰度级为 $[0,255]$ 的灰度图像经过归一化的像素值，要求归一化的主要原因是当神经网络的输入和输出在 $[0,1]$ 这个范围内时，其运行效率更高^[54]。

3.2.3 性能参数

用基本的 BP 网络来进行图像压缩分为两个阶段：训练和编码^[55]。第一阶段：

将图像数据样本集作为输入和教师信号训练 BP 网络，得到 h_j 、 w'_{ij} 和 b'_i ；第二阶段：对 h_j 、 w'_{ij} 和 b'_i 进行熵编码。那么 BP 网络图像压缩中比特率定义为：

$$\text{比特率} = \frac{LKT + NKt}{NL} \quad (\text{bits/pixel}) \quad (3.27)$$

这里输入图像被分为 L 个 N 维矢量， T 和 t 分别代表编码一个 h_j 需要的比特数和编码一个耦合权值（即 w'_{ij} 与 b'_i ）需要的比特数， K 是隐含层神经元的个数。当神经网络训练好以后，网络的耦合权值在这个压缩过程中保持不变，这时 NKt 可以忽略不计，因此比特率就变成了 KT/N （比特/像素）。既然隐含层神经元输出为真值，那么就要求用固定长熵编码，一般情况下就设计为 32 级均匀量化，对应 5 位熵编码^[19,56]。

压缩比和比特率主要是用来评价图像的压缩性能，而另外还有一些评价重建图像的质量的性能参数^[3]，如信噪比（SNR）和峰值信噪比（PSNR），其定义如下：

$$SNR = 10 \log \frac{\sum_{i=1}^K \sum_{j=1}^N [x(i, j)]^2}{\sum_{i=1}^K \sum_{j=1}^N [x(i, j) - \hat{x}(i, j)]^2} \quad (3.28)$$

$$PSNR = 10 \log \frac{255^2}{\frac{1}{KN} \sum_{i=1}^K \sum_{j=1}^N [x(i, j) - \hat{x}(i, j)]^2} \quad (3.29)$$


式中， $x(i, j)$ 代表原始图像像素的灰度值， $\hat{x}(i, j)$ 代表重建图像像素的灰度值。

3.3 关键技术

本文的目的是图像压缩，其中解释实验中所用到的关键技术以及实验步骤是至关重要的，主要包括下面几个方面。为了便于分析实验结果，实验中采用 256×256 Lena 图像作为标准样本图像，其比特率为 8bits/pixel。

3.3.1 训练样本构造

试想把一幅图像的所有像素点作为压缩网络的输入，则图像的尺寸越大需要的网络规模越大。对于神经网络，规模越大则越难于训练，不但网络训练时间变长，而且难于收敛到预定目标。因此，应适当控制网络规模，即转化为图像的划分问题。先将待压缩图像划分成 M 个子图像块，具体的划分方式如图 3.9 所示。设待压缩图像由 $N \times N$ 个像素点构成，将其划分成 M 个子图像块，每个子图像块都分别由 $p \times p$ 的子像素块构成。

图 3.9 图像划分示意图 (图像 \Rightarrow 图像子块 \Rightarrow 像素块)Fig3.9 The partition of image(image \Rightarrow subimage \Rightarrow pixel patch)

下面以 256×256 的图像像素矩阵划分成 4×4 子像素块矩阵为例来说明训练样本的生成情况。

$$\begin{bmatrix} [1]_{4 \times 4} & [2]_{4 \times 4} & \Lambda & \Lambda & [64]_{4 \times 4} \\ [65]_{4 \times 4} & [66]_{4 \times 4} & \Lambda & \Lambda & [128]_{4 \times 4} \\ M & M & O & & M \\ M & M & & O & M \\ [4033]_{4 \times 4} & [4034]_{4 \times 4} & \Lambda & \Lambda & [4096]_{4 \times 4} \end{bmatrix}_{64 \times 64} \Rightarrow \begin{bmatrix} [1]_{4 \times 4} & [2]_{4 \times 4} & \Lambda & \Lambda & [4096]_{4 \times 4} \end{bmatrix}_{16 \times 4096}$$

由上面的方法生成的像素块矩阵还必须进行归一化处理, 本文采用的是均值分布预处理: 设待处理图像的灰度范围为 $[x_{\min}, x_{\max}]$, 变换域为 $[y_{\min}, y_{\max}]$, 令当前待处理的像素灰度值为 a_{value} , 则对于有所过程的映射 y_{value} 为:

$$y_{value} = \frac{(y_{\max} - y_{\min})(x_{value} - x_{\min})}{x_{\max} - x_{\min}} + x_{\min} \quad (3.30)$$

用式 (3.30) 将原始图像的像素值划到 $[0,1]$ 的范围内, 这样就完成了的样本的所有预处理过程。

3.3.2 训练算法

用 3.3.1 中构建的输入矩阵, 每一列代表一个输入模式, 用输入矩阵作为目标输出矩阵, 开始训练网络。训练过程中采用不同的学习算法, 这些算法大致分为两类: 慢速算法和快速算法。

慢速算法有: 梯度下降法。这类算法最简单, 收敛较慢, 但是如果学习速度不太快或每步都实现极小化, 最速下降法能够确保收敛, 并且该算法具有较强的记忆能力。

快速算法有: 牛顿法和 Levenberg-Marquardt 算法。牛顿法的收敛速度通常比最速下降法更快, 但其表现很复杂, 算法可能振荡和发散, 而 LM 算法是牛顿法的变形^[8], 算法收敛的迭代次数较前面讨论的所有算法都少, 是最快的 BP 网络训练算法, 但是该算法在每次迭代时的运算量比任何其它算法大 (因为必须求矩阵

的逆), 因此对高等数量的网络参数, 要作大量计算, 对计算机的配置要求很高, 否则根本无法运算。

3.3.3 编码仿真结果

用 3.3.2 中的各种算法训练网络, 然后仿真。如果隐含层神经元为 K , 则网络的隐含层产生 $K \times 4096$ 的矩阵, 隐含层和输出层之间产生 $16 \times K$ 的权值矩阵, 输出层产生 16×1 的阈值矢量, 分别对上述仿真结果进行熵编码, 由于本文的重点不在编码阶段, 因此采用 5 位熵编码。

3.3.4 图像重建

先对熵编码后的比特流进行解码, 得到隐含层输出 h_j 和耦合权值 (w'_{ij} 与 b'_i), 代入(3.26)式计算出网络输出 y_i , 它是一个 16×4096 的矩阵, 每个矩阵元素分别乘以 255, 把各像素值从 $[0,1]$ 恢复为 $[0,255]$, 再把每个列向量变形成图像块, 把所有图像块组合成一幅完整的图像, 从而完成图像的重建工作。

3.4 实验结果与分析

仿真实验过程中, 分别采用了不同的训练算法、不同的隐含层神经元数和不同的传输函数。

3.4.1 实验一: 采用不同的训练算法进行仿真

(1) 最速下降法

最速下降法是改进后的最速下降法, 使用了梯度下降动量和自适应学习率, 由于该算法收敛速度较慢, 因此实验中把目标误差设为 0.001, 取不同的隐含层神经元数来训练网络, 其压缩性能见表 3.1, 压缩后恢复图像见图 3.10。从重建图像的效果可以看出当隐含层神经元数较少 ($K=2$) 时, 压缩比较高, 但是重建图像质量较差, 所以在仿真实验过程中, 通过增加隐含层的神经元数来提高重建图像的质量。




图 3.10 基于最速下降法的重建图像

Fig3.10 The reconstructed image based on steepest descent

表 3.1 基于最速下降法重建图像的压缩性能

Table3.1 The compression performance of the reconstructed image based on steepest descent

隐含层神经元	峰值信噪比 (dB)	信噪比 (dB)	比特率 (bits/pixel)
2	59.0910	42.4757	0.625
4	63.9058	47.2905	1.25
8	65.9550	49.3397	2.5

(2) 牛顿法

本实验中采用了牛顿法，由于该算法的收敛速度快，因此提高误差精度，把网络的目标误差设为 0.0001，同样取不同的隐含层神经元数来训练网络，其压缩性能见表 3.2，压缩后恢复图像见图 3.11。相比图 3.10，图 3.11 的重建效果要好些，图 3.11 (c) 的峰值信噪比达到了 74.1752，其视觉效果接近原始图像。




图 3.11 基于牛顿法重建图像

Fig3.11 The reconstructed image based on Newton's method

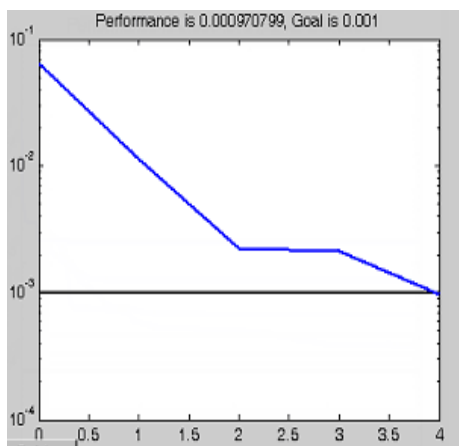
表 3.2 基于牛顿法重建图像的压缩性能

Table3.2 The compression performance of the reconstructed image based on Newton's method

隐含层神经元	峰值信噪比 (dB)	信噪比 (dB)	比特率 (bits/pixel)
2	59.0682	42.4529	0.625
4	66.1412	49.4766	1.25
8	74.1752	57.4400	2.5

(3) LM 算法

运用 LM 算法，网络的目标误差设为 0.0001，由于要求的计算机内存很大，所以仅仅实现过一次，其网络训练的误差曲线和重建图像见图 3.12。从 (a) 图可以看出 LM 算法收敛速度很快，迭代 4 次就达到了目标误差，但是重建图像有较小的网格效应，其峰值信噪比 $PSNR = 60.0032$ dB，信噪比 $SNR = 43.3514$ dB；由于每次迭代的运算量很大，迭代四次所花的时间并不短，共花了 274.1 秒钟。



(a) 训练误差曲线

(a) Error curve



(b) 重建图像

(b) Reconstructed image

图 3.12 基于 LM 算法的训练结果

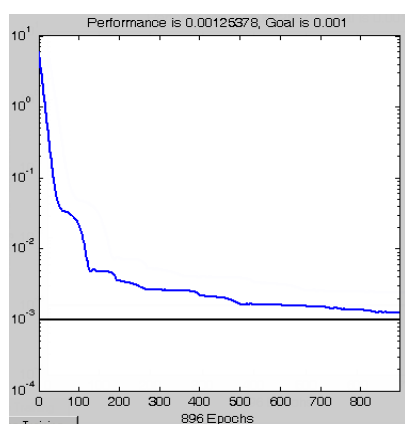
Fig3.12 The training results based on LM algorithm

3.4.2 实验二：线性和非线性性的比较

线性网络和非线性网络用于图像压缩，到底谁占优势？这个问题至今都没有定论，也没有得到严格的证明。文献[16]中的实验结果表明非线性网络性能优于线性网络，网络的抗噪性强，通用性更好，而文献[48]用了大量的实验说明了线性网络优于非线性网络。本文从训练时间和恢复图像性能来说明线性网络优于非线性网络。实验中，分别在隐含层和输出层加上线性传输函数（即式（2.24））构成线性网络；而分别在隐含层和输出层加上 sigmoid 函数（即式（2.23））和线性传输函数构成非线性网络。


(1) 最速下降法

采用最速下降法，其他参数都相同的情况下，分别用线性和非线性激活函数训练网络，得到的训练结果见表 3.3，训练误差曲线见图 3.13。从图 3.13 可以看出，线性网络比非线性网络收敛速度快得多。从表 3.3 的数据记录可知，线性网络迭代 896 次，网络误差达到 0.00125，训练时间为 67.09 秒；而非线性网络迭代了 3571 次才达到与前者一样的压缩性能，花了前者的四倍的时间。



(a) 线性

(a) Linear



(b) 非线性

(b) Non-linear

图 3.13 基于最速下降法的线性和非线性训练误差曲线

Fig3.13 The error curve based on steepest descent


表 3.3 基于最速下降法的线性和非线性训练结果

Table3.3 The training results based on steepest descent

	时间 (秒)	峰值信噪比 (dB)	信噪比 (dB)	迭代次数
线 性	67.0985	66.8122	50.2011	896
非线性	290.8223	66.8187	50.2109	3571


(2) 牛顿法

采用牛顿法，其他参数都相同的情况下，分别用线性和非线性激活函数训练网络，得到的训练结果见 3.4，训练性能曲线见图 3.14。从表 3.4 和图 3.14 的结果对比可知，当网络误差都达到 0.00121，非线性网络迭代了 571 次，训练时间为 128.4123 秒，而线性网络只迭代了 141 次，仅仅花了 27.2421 秒。由此可见，线性网络比非线性网络的收敛速度快得多，即要达到同样的压缩性能，线性网络比非线性网络的实时性好。



(a) 线性

(a) Linear



(b) 非线性

(b) Non-linear

图 3.14 基于牛顿法的线性和非线性训练误差曲线

Fig3.14 The error curve based on Newton's method

表 3.4 基于牛顿法的线性和非线性训练结果

Table 3.4 The training results based on steepest descent

	时间 (秒)	峰值信噪比 (dB)	信噪比 (dB)	迭代次数
线 性	27.2421	67.1120	50.4929	141
非线性	128.4123	67.1085	50.4879	571

3.5 多级 BP 网络实现图像压缩

3.4 节讨论了用单个 BP 网络实现图像压缩, 这个压缩过程减少或消除了每个图像块内的相关性。但是, 通常对于一幅图像而言, 不但存在图像块内的相关性, 而且存在图像块之间的相关性。因此, 作者认为, 如果综合考虑这两种相关性, 必然能进一步提高图像的压缩性能。作者首次提出利用多级 BP 网络来实现图像压缩, 这种方法在单个 BP 网络实现图像压缩的基础上增加了两层, 即分解层和组合层, 进行了两次压缩, 大大减小了原始图像的冗余度, 从而进一步提高了压缩比。

3.5.1 基于多级 BP 网络的图像压缩的网络模型

如果在原有两层网络的基础上, 增加一个新的隐含层单元, 则构成一个具有一个输入层、一个输出层, 两个隐含层的三层神经元网络。仍然按照 BP 算法训练网络, 则在输入层到第一个隐含层实现图像的第一次压缩, 这次压缩依据同一图像块内相邻像素点间的相关性; 第一隐含层到第二隐含层实现图像的第二次压缩, 这次压缩建立在第一次压缩的基础上, 依据第一次压缩结果的相关性, 即像素块间的相关性。直观的理解, 可以看作第一次压缩的局部区域, 第二次压缩则把所有局部区域作为一个整体, 把每个局部区域具有的相关性的数据继续再次压缩。

多级 BP 网络的图像压缩方法, 从压缩机理的角度, 更具科学性, 但是从实际的实验结果看来, 增加了算法的复杂度及网络训练时间。另外, 大部分的实验表明, 由于中间数据的量化处理过程给图像压缩带来一定的损失, 因此随着隐含层的增多, 使图像压缩后的重建图像质量下降。因此最多采用三个隐含层的组合压缩网络。图 3.15 是一个不完全连接的多级组合网络结构图, 由于压缩网络和解压网络的对称性特点, 则设计出的网络压缩和解压系统具有对称性。训练图像被划分成的 M 个子图像块构成了 M 个不同的训练样本集, 每个样本集训练一个网络(输入层—隐含层—输出层), 则生成 M 个外层子网。接着把 M 个外层子网的中间层输出合成一个新的训练样本集合, 训练另外一个网络(输入层—隐含层—输出层), 称为内层网络。最后, 合成这 $M+1$ 个网络为一个完整的压缩—解压系统。




图 3.15 多级 BP 网络结构图

Fig3.15 Hierarchical BP neural network structure

从图 3.15 可以看出，整个系统由输入层、组合层、压缩层、分解层和输出层构成。其中输入层和输出层分别对应 M 个外层子网的输入层和输出层；分解层和组合层对应于内层子网的输入层和输出层。 M 个外层子网的输入层到其隐含层和隐含层到输出层的连接权分别对应于图中合成网络的输入层到组合层和分解层到输出层的连接权。内层网络的输入层到隐含层和隐含层到输出层的连接权对应于合成网络结构的组合层到压缩层和压缩层到分解层的连接权。

将图像分成 M 个互不重叠的子块，每个子块又分成 T 个 $p \times p$ 的子像素块，这样构成的矢量作为输入模式输入网络。以一个大小为 256×256 的标准 Lena 图像为例，它被分为 8 个子块，每个子块又被分成 128 个 8×8 的子像素块，因此网络参数设置为：

输入层的神经元总数 = $Mp^2 = 8 \times 64 = 512$ ；

组合层的神经元总数 = $MN_h = 8 \times 8 = 64$ ；

压缩层的神经元总数 = $Q = 8$ 。

那么由对称性可知，分解层和输出层的神经元数分别等于组合层和输入层的神经元数。

3.5.2 多级网络的嵌套式训练算法

多级网络运用嵌套式训练算法（Nested training algorithm，简称 NTA）可以缩短训练时间，其主要步骤如下：

（1）外环神经网络（Outer loop neural network，简称 OLNN）训练（输入层—隐含层—输出层）




图 3.16 外层网络结构框图

Fig3.16 Outer loop neural nets

如图 3.16 所示，由输入层、隐含层和输出层组成的外环神经网络是一个全连接的两层对称网络。这样外环网输入层和输出层分别有 64 个节点，隐含层有 8 个节点，构成 64—8—64 外环网。其训练过程与 3.4 节中相同，就是把输入作为理想的输出并采用标准的 BP 训练算法。连接权值在网络收敛后可以获得。另外，从 3.5.1 可知，训练模式来自于每个子图像块中的 8×8 子像素块，对于每个外环网有 128 个训练模式，共有 8 个外环网。

(2) 内环网络 (Inner loop neural network, 简称 ILNN) 训练 (组合层—压缩层—分解层)

提取出图 3.15 中的三个隐含层，就构成了内环网络，如图 3.17 所示。由 3.5.1 可知，内环网也是一个 64—8—64 网络，相应于步骤 (1) 的外环训练中也就会有 8 个隐含层输出集，而每一个隐含层输出集由 128 个 8 维矢量构成。因此，内环网络的训练集同样包含 128 个训练模式，每个训练模式是一个 64 维矢量，这是把外环网的隐含层输出直接应用于内环网的训练中。另外，这里仍然应用的是标准的 BP 网络算法。在内环网络和外环网络中均采用的是线性变换。




图 3.17 内环网络结构图

Fig3.17 Inner loop neural network structure

(3) 网络重构

实际网络的连接权与训练过程中的权值关系对应如下：

组合层——压缩层——分解层：同第（2）步的内环网络的权值；


输入层——组合层和分解层——输出层：把输入和输出图像分别加到组合层和分解层的外面，连接权为第（1）步产生的连接权值。

在以上两步的训练过程中共获得 4 个权值集合，其中每一步产生 2 个。从步骤（1）获得的两组权值分别用于连接输入层到组合层和分解层到输出层。而步骤（2）获得的两组权值分别用于连接组合层到压缩层和压缩层到分解层。

在训练完成以后，对称神经网络的一半用于图像编码，另一半用于图像解码。在整个过程中，神经元间的连接权值以及阈值保持不变。

3.5.3 实验结果分析

按照上面的步骤，在 MATLAB 环境下实现了多级 BP 网络图像压缩。在压缩比接近 64 的情况下，重建图像效果如图 3.18（b）所示，其信噪比仅为 19.3023，与原始图像对比，重建图像的视觉效果较差，有明显的失真，图像的边缘部分失真更大，从而显得比较模糊，其主要原因是这种方法要经过两次压缩，加大了失真程度，另外这种方法先后要训练 9 个 64—8—64 的 BP 网络，训练时间就大大增加了，至少是单个 BP 网络实现图像压缩的训练时间的 9 倍，因此这种方法是牺牲训练时间换来较高的压缩比，这会直接导致实时性下降。但是这毕竟是一种新的尝试，如果要用在实际中，就必须开发新的快速算法，所以有待进一步研究。



(a) 原始图像
(a) Original image



(b) 重建图像
(b) Reconstructed image

图 3.18 多级 BP 网络实现图像压缩

Fig3.18 Image compression by Hierarchical BP neural network

3.6 本章小结

本章实现了单个 BP 算法在图像压缩中的应用，并且介绍用于图像压缩的 BP 网络的各种训练算法的比较，线性网络与非线性网络的比较。分别采用最速下降法、牛顿法和 LM 算法实现了图像压缩，其中 LM 算法的收敛速度最快，但它的运算量太大，对大型结构的网络很难实现，而最速下降法和牛顿法用于图像压缩时，只能牺牲压缩率，通过增加隐含层的神经元数来提高重建图像的质量。两者相比，牛顿法比最速下降法收敛速度快，所以用牛顿法训练时，可以适当提高目标误差，从而提高重建图像的质量。从仿真实验得知线性网络比非线性网络收敛速度快。总之，三层前馈网络用于图像压缩，关键在于各种参数的选择，比如，算法、激活函数和隐含层神经元数，它们将会直接影响收敛时间和压缩性能，这些方面的研究是有必要的，为实际应用打下基础。

本章还深入研究了多级 BP 网络实现图像压缩的理论基础、算法、网络模型以及系统的搭建，这是一种新的尝试，并且在现有的条件下实现了图像的压缩与重建，虽然该方法所需要的训练时间很长，但是得到了更高的压缩比，虽然这种方法在实际应用中缺乏可行性，但是作为理论研究，它却具有不可忽视的价值。

4 基于自组织特征映射网络的图像压缩

从第一章的绪论中可知：目前，图像编码的方法多种多样，图像编码技术也得到了空前的发展。由于矢量量化技术能有效利用矢量中的各分量之间以及矢量与矢量之间的关联特性来消除冗余，使它能在众多压缩方法中占有一席之地，并作为一种高效的数据编码技术广泛应用于图像和语音信号的数据压缩中。因此，本章主要探讨矢量量化理论和 SOFM 神经网络的基本理论，深入研究基于自组织特征映射网络的图像压缩方法，并以实验来说明这种方法的可行性，在此基础上用大量实验说明了 SOFM 矢量量化中各种参数的选择对压缩性能的影响，并对此进行系统而全面的分析。

4.1 矢量量化的理论研究

4.1.1 矢量量化的基本原理

矢量量化 (Vector Quantization, 简称 VQ), 是标量量化的自然发展产物, 它是相对于一维情形下的标量量化 (Scalar Quantization) 提出的, 其有效地利用了矢量中各分量间的四种相关性: 线性依赖性、非线性依赖性、概率密度函数的形状以及矢量维数来进行去相关处理, 而标量量化只利用了线性依赖性和概率密度函数的形状。因此, 矢量量化在保证一定的图像质量的条件下可获得较高的压缩比。现在已把矢量量化作为一种独立的编码手段来考虑, 而不仅仅是一种量化技术。从本质上来看, VQ 是一种聚类分析的方法, 即根据有限的矢量集 $Y = \{Y_i, Y_i \in R^k, i = 1, 2, \dots, N\}$ 将欧氏空间 R^k 按某种矢量度量划分为不相交的子空间 $\{R^i, i = 1, 2, \dots, N\}$, 这种划分应该为 Y 的最邻近域 (nearest neighbor) 划分, 即 Voronoi 划分。任何一个输入矢量 X 均可以按这种划分归为某一子空间, 并且用 Y_i 表示。 X 是由像素方块组成的输入矢量, 编码器的输出为二进制序号 in , 该 in 在解码端指定了重构矢量的序号。如果码率为固定码率 b bits/输入矢量。则 in 的长度为 b 。对于变码率的情况, 序号的长度也是可变的, 此时 b 为平均码长。压缩图像可由这些 in 来描述, 因为它们所要求的比特数比原始图像少。

对于一个 k 维的矢量量化器可以定义为 k 维欧氏空间 R^k 到其有限子集 Y 的映射 Q , 即

$Q: R^k \rightarrow Y$, 其中 Y 在 VQ 中称为再生矢量集或再生码本。从编码角度理解, 这一映射也可看成是由两部分组成: 第一部分由输入矢量 X 按某种矢量度量准则 $d(X, \hat{X})$ 产生码本中对应 $d(X, Y_i)$ 最小的索引 in , 称为编码器; 另一部分则根据索引 in 再生矢量 Y_i 的工作, 称为解码器。显然, Y_i 应是失真度量 $d(X, Y_i)$ 下 X 的最佳逼近 \hat{X} 。它们的理论工具是 Shannon 的率失真编码理论。该理论指出: 不论信源

有无记忆，组编码总是优于单个编码的。当编码长度（即矢量维数） $K \rightarrow \infty$ 时，矢量量化编码可以达到率失真边界， K 越大，离率失真边界越近，这为矢量量化编码的研究奠定了良好的理论基础。

4.1.2 矢量量化中的码书设计

图 4.1 给出了一个矢量量化器框图，设计一个 VQ 系统，主要包括三个部分，即码书的生成、搜索器（即量化器）的构造、索引器以及逆索引器的构造。




图 4.1 矢量量化器构造框图

Fig4.1 Block diagram of vector Quantizer

所谓码书是矢量空间中的一个有限子集，即由若干码字矢量组成，编码器根据特定的距离准则在码书中对输入图像进行矢量匹配，然后对匹配码字的序号进行编码，从而实现图像的压缩。而解码器则根据码字序号对照码书恢复图像。

搜索器的功能是完成输入矢量与所有可能相邻的码字矢量之间的范数计算，并从中取得最小范数值所对应的码字作为搜索的结果。

索引器比较简单，它由映射定义，实现起来比较简单。

从上面的叙述中，可以看出搜索器和索引器的性能主要是影响系统的运算复杂度和编码效率，应该采用最优化算法减少运算和冗余。而码书则决定了编码器和解码器的整体性能，影响重建图像的质量。因此，码书的设计算法是矢量量化的一个关键问题。

码书的设计过程是一个基于信号分布、矢量维数、码书大小并以平均量化误差为代价函数的设计算法。在设计时，一般都采用很大而又有限的样本集来训练网络去拟合实际信号的统计特性，并通过对这个训练集的反复迭代，获得一个较好的能够反映这个训练集体现出的信源特性的码书集。这就要求矢量量化器的码书设计算法能够根据给定的训练集找出最优的码书集；同时要求码书设计算法具有自适应性能，从而能够自动跟踪实际信源的统计特性的变化，及时对矢量量化的码书集进行调整。

利用 SOFM 网络进行码书设计是可行的，并且是一种成熟的算法，下面从研究 SOFM 的基础理论出发，说明用 SOFM 网络进行码书设计的机理。

4.2 SOFM 网络的理论研究

自组织特征映射（SOFM）神经网络是芬兰学者 Kohonen 提出的一种竞争性神

神经网络。下面简要介绍 SOFM 神经网络的基本思想、学习规则、几何解释及其自组织特性。

4.2.1 SOFM 网络的基本思想

科学家通过生理学实验发现：在人的大脑皮层中存在着许多完成特定功能的网络区域。如语言了解、视觉、控制运动等功能，都分别是由不同的神经网络区域完成的。而进一步的实验又发现：在完成某一特定功能的网络区域中，不同部位的若干神经元对含有不同特征的外界刺激同时产生响应。这就是说，人脑的神经细胞（神经元）并不是与记忆模式一一对应的，而是一组或一群神经元对应一个模式。生理学实验早已证实人脑的神经细胞是不断消失的，同时又不断产生大量新的神经细胞。假设神经细胞与记忆模式一一对应，则一旦某个细胞消失或损坏，则与之对应的记忆信息也随之全部消失，显然这是与客观事实不相符的。另一方面，大脑神经网络中各细胞之间的信息是通过神经键传递的，传递的结果有抑制和兴奋之分。生理学基础实验表明：某一个外界信息所引起的并不是对一个神经细胞的兴奋性刺激，而是对以某一个细胞为中心的一个区域内的神经细胞的兴奋刺激，并且这种刺激的强度不是均匀的，有强弱之分。如图 4.2 所示，大脑神经的刺激趋势和强度成墨西哥帽的形状。神经元受兴奋刺激的强度以区域中心为最大，随着区域半径的增大，强度逐渐减弱，远离区域中心的神经元相反要受到抑制性作用。




图 4.2 墨西哥帽函数

Fig4.2 Function like a Mexican hat

早在 70 年代，一些学者就曾根据这些生理学规律研究并提出了各种模拟这些规律的人工神经网络模型和算法。之后于 1981 年芬兰学者 Kohonen 提出了一个比较完整和分类性能较好的自组织特征映射神经网络，有时也称为 Kohonen 特征映射网络。

SOFM 神经网络的结构如图 4.3 所示。由图可知 SOFM 由输入层和竞争层组成。输入层由 N 个输入神经元组成，竞争层由 $m \times m$ 个输出神经元组成，且形成一

个二维平面阵列。输入层各神经元与竞争层各神经元之间实现全互连接。有时，竞争层各神经元之间也实行相邻神经元侧抑制连接。




图 4.3 二维阵列 SOFM 网络结构

Fig4.3 SOFM neural network structure of two-dimensional array

SOFM 网络根据其学习规则，对输入训练模式进行自动分类，即在无教师示教的情况下，通过对输入模式的反复学习，捕捉住各个输入模式中所含的模式特征，并对其进行自组织，在竞争层将分类结果表现出来。这种表现方式与其他类型的网络的区别是：它不是以一个神经元来反映分类结果，而是由若干神经元同时反映分类结果。与这若干个神经元相连接的权向量略有差别，但这些神经元的分类作用基本上是并列的，即其中任何一个神经元都可以代表分类结果或近似分类结果。一旦由于某种原因，某个神经元受到损害，剩下的神经元仍可以保证所对应的记忆信息不会消失。从这一点上看，SOFM 网络完全模拟了人脑神经细胞对外界信息刺激的反映，克服了所谓“祖母细胞”现象。另外由于网络对输入模式的记忆不是一次性完成的，而是通过反复学习，将输入模式的统计特征“融解”到各个连接权上，所以这种网络具有较强的抗干扰能力。

4.2.2 一般的 SOFM 网络学习规则

设网络的输入模式集为 $X_k = (x_1^k, x_2^k, \Lambda, x_N^k)$ ($k = 1, 2, \Lambda, p$) (其中 p 为训练模式总数)。网络的连接权为 $\{w_{ij}\}$ ($i = 1, 2, \Lambda, N; j = 1, 2, \Lambda, M$) (其中 N 和 M 分别为输入层和竞争层节点的个数)。

SOFM 神经网络的学习、工作规则如下：

(1) 初始化：将网络的连接权 $\{w_{ij}\}$ 赋予 $[0,1]$ 区间内的随机值，确定学习率 $\eta(t)$ 的初始值 $\eta(0)$ ($0 < \eta(t) < 1$)，确定邻域 $N_g(t)$ 的初始值 $N_g(0)$ 。所谓邻域 $N_g(t)$ 是指在以步骤 (4) 确定的获胜神经元 g 为中心、包含若干神经元的区域范围。这个区域可以是任何形状，但一般来说是均匀对称的，最典型的是正方形或圆形区域。 $N_g(t)$ 的值表示在第 t 次迭代时邻域中所包含的神经元的个数。确定总迭代次数为 T 。

(2) 给网络提供输入模式 $X_k = (x_1^k, x_2^k, \Lambda, x_N^k)$ ($k=1, 2, \Lambda, p$)。

(3) 计算连接权矢量 $W_j = \{w_{ij}, w_{2j}, \Lambda, w_{Nj}\}$ 与输入矢量 $X_k = (x_1^k, x_2^k, \Lambda, x_N^k)$ 之间的距离:

$$d_j = \sum_{i=1}^N (x_i^k - w_{ij})^2 \quad (j=1, 2, \Lambda, M) \quad (4.1)$$

(4) 找出最小距离 d_g , 确定获胜神经元 g :

$$d_g = \arg \min_M d_j \quad j=1, 2, \Lambda, M \quad (4.2)$$

(5) 进行连接权值调整: 将输入神经元到 $N_g(t)$ 范围内的所有竞争层神经元之间的连接权按式 (4.3) 进行修正:

$$w_{ij}(t+1) = w_{ij}(t) + \eta(t) \cdot [x_i^k - w_{ij}(t)] \quad (4.3)$$

$$j \in N_g(t), i=1, 2, \Lambda, N \quad 0 < \eta(t) < 1$$

上式中 $\eta(t)$ 为第 t 次迭代的学习率。

(6) 将下一个输入训练模式提供给网络的输入层, 返回步骤 (3), 直至 p 个训练模式全部提供一遍。

(7) 更新学习率 $\eta(t)$ 及邻域 $N_g(t)$:

$$\eta(t) = \eta(0) \cdot \left[\eta_g(0) \cdot \left(1 - \frac{t}{T} \right) \right] \quad (4.4)$$

式中 $\eta(0)$ 为学习率的初始值, t 为迭代次数, T 为总的迭代次数。

设竞争层某神经元 g 在二维阵列中的坐标值为 (x_g, y_g) , 则邻域的范围是以点 $(x_g + N_g(t), y_g + N_g(t))$ 和点 $(x_g - N_g(t), y_g - N_g(t))$ 为右上角和左下角的正方形。其修正公式为:

$$N_g(t) = INT \left[\eta_g(0) \cdot \left(1 - \frac{t}{T} \right) \right] \quad (4.5)$$

式中 $INT[x]$ 为取整符号, $N_g(0)$ 为 $N_g(t)$ 的初始值, t 和 T 与式 (4.4) 中定义相同。

(8) 令 $t=t+1$, 返回步骤 (2), 直至 $t=T$ 为止。

从上面的叙述中可以看出 SOFM 网络的学习和工作规则主要包括三个步骤:

- (a) 寻找与输入模式 X_k 最接近的连接权向量 $W_g = \{w_{1g}, w_{2g}, \Lambda, w_{Ng}\}$ 。
- (b) 将连接权向量 W_g 进一步朝与输入模式 X_k 接近的方向调整。
- (c) 除调整连接权向量 W_g 外, 还要调整邻域内的各个连接权向量 W_j ,

$j \in N_g(t)$ ，并且随着迭代次数的增加，邻域 $N_g(t)$ 逐渐减小。

上面三点体现了 4.2.1 中所介绍的大脑神经网络信息传递的规律与效果。

4.2.3 SOFM 网络的几何解释

由式 (4.3) 可知，权矢量 $W_j(t+1)$ 实际上是权矢量 $W_j(t)$ 与训练矢量 X_k 的加权和。图 4.4 的几何表示说明了权矢量（码字）的调整过程，点 A 代表权矢量 $W_j(t+1)$ ，点 B 代表权矢量 $W_j(t)$ ，点 C 代表训练矢量 X_k 。按式子 (4.4) 修正后的权矢量 A 位于 B 和 C 两点之间的连线上，即调整的过程使点 B 向训练矢量 X_k 所在的位置靠拢。




图 4.4 SOFM 权值修正的几何表示

Fig4.4 Geometric denotation of weight value being modified in SOFM neural network

4.2.4 SOFM 网络的自组织特性

SOFM 神经网络的自组织能力表现在：经过网络的学习，竞争层中各神经元的连接权向量的空间分布能够正确反映输入模式的空间概率分布。而模式的概率分布函数表示了相应的模式空间中模式分布的统计规律，即对于模式空间中的任意一点，模式的概率分布函数定义为在这一点上模式出现的可能性大小。如果给定了由网络输入层 N 个神经元所形成的模式空间的模式概率分布函数，即预先知道了输入模式的分布情况，则通过对按给定的概率分布函数产生的输入模式的学习，网络竞争层各神经元连接权向量的空间分布密度将与给定的输入模式的概率分布趋于一致。换句话说，学习后的网络连接权向量的空间分布将符合输入模式的空间概率分布，这些连接权向量可作为这类输入模式的参考向量。作为网络这一特性的逆应用，当一组输入模式的规律分布情况未知时，可以通过让网络对这组输入模式进行学习，最后由网络的连接权向量的空间分布把这组输入模式的规律分布情况表现出来。所以有时也称 SOFM 神经网络为学习矢量量化器。

4.3 基于 SOFM 神经网络的矢量量化

通过比较上面所述的矢量量化器和 SOFM 神经网络，可以发现两者之间有着非常相似的地方。SOFM 神经网络由许多神经元构成，它们排列成一个一维或者二维的阵列，通过学习后，阵列中的每个神经元对于矢量空间的某个小空间中的矢量最为敏感，当输入此小空间内的矢量时，该神经元的输出达到最大可能输出

值，而其它神经元的输出为最低可能值。在这一方面，SOFM 神经网络与矢量量化器非常相似，即对于每一分量都具有连续变化值的高维输入矢量，两者的输出都可以用一个离散的标点来表示，对于前者，这是最小误差或距离的质心的标点，对于后者，则是最大输出神经元在阵列中所处位置的标号。此外，两者都对输入矢量所包含的信息进行了压缩，而且能够反映输入矢量在空间中的概率分布密度。所以利用 SOFM 网络是可以进行矢量量化的。

矢量量化中，码书设计是核心问题。LBG 算法作为矢量量化的基本算法具有经典意义，但由于在训练图象中，总存在少量的离群矢量，使得在训练码书时，码字的分布受到影响，进而使得压缩性能下降，因而不能充分体现出矢量量化的优越性能。总体来说 LBG 算法存在两个缺点：一是对初始码书很敏感，初始码书的设计是 LBG 算法的关键；二是 LBG 算法是一种批处理算法，每次迭代需要处理所有的训练数据，缺乏一定的灵活性和自适应性，同时训练时间长、并存在无效码矢。而运用自组织特征映射网络来设计矢量量化器，减少了码书中的离群矢量，同时加强了中心矢量在码书中的权重，不仅能够尽量减少码书的冗余，而且能大幅度提高压缩性能，即能有效地克服 LBG 算法的上述缺点。本节主要讨论自组织特征映射网络在矢量量化中的实际应用问题，首先从参数的选择入手讨论。

4.3.1 学习率 $\eta(t)$ 及邻域 $N_g(t)$ 的选择

在码矢权值的修正过程中，学习速率因子 $\eta(t)$ 是一个直接影响到算法收敛速度和性能的重要参数。 $\eta(t)$ 反映了码矢分量变化调整的幅度大小。理论上讲， $\eta(t)$ 越小，经过很长时间训练后，网络能量函数能达到极小值，即全局极小点，获得最佳码书。但在实际应用中， $\eta(t)$ 太小，训练所花费的时间将太长。然而如果 $\eta(t)$ 太大的话，容易使网络产生“之”字型震荡。针对这一问题，本文提出了修改学习速率因子应该遵循的规则：

- (1) 首先为了保证算法的收敛性，学习速率应该满足以下两个条件^[59]：

$$\frac{\partial \eta(t)}{\partial t} < 0 \quad 0 < \eta(t) < 1 \quad (\text{条件 1})$$

$$\lim_{t \rightarrow \infty} \eta(t) = 0 \quad (\text{条件 2})$$

- (2) 在远离全局最小点时，不论误差平面是陡还是缓，较大的学习步长有利于加快算法的收敛速度，并且较大的步长有利于跳过一些局部最小点，如图 4.5 所示。




图 4.5 跨越极小点的情况

Fig 4.5 The case of jumping over the minimal point




图 4.6 震荡情况

Fig 4.6 The case of concussion

(3) 在接近全局最小点时, 不论误差平面是陡还是缓, 学习步长都应该较小, 这样有利于靠近全局最小点。如果学习步长太大, 容易使网络发生震荡, 如图 4.6 所示。

作者根据以上学习速率变化所应遵循的规则提出了新的学习变化公式:

$$\eta(t) = \eta(0) \cdot \exp(-t/T_1) \quad (4.6)$$

其中 t 是迭代次数, T_1 是衰减常数, $\eta(0)$ 是初始学习速率。我们可以看出: 当迭代次数 t 趋向于无穷大时, 学习速率因子趋向于 0。所以选取的学习速率变化公式符合算法收敛的条件。

同理, 邻域修正公式如下:

$$N_g(t) = A_1 + A_2 \cdot \exp(-t/T_2) \quad (4.7)$$

式中, A_1 为最小邻域, A_2 为开始训练时的最大邻域, T_2 是衰减常数。

可以把 SOFM 网络的学习过程分为两个阶段: 第一阶段为粗学习和粗调整阶段。在这个阶段内, 各随机方向的连接权矢量朝着输入模式的方向进行调整, 并大致确定各输入模式在竞争层中所对应的映射位置。一般此阶段的 $\eta > 0.5$ 。一旦各输入模式有了对应的映射位置后, 则转入第二阶段——精学习和精调整阶段。在这一阶段内, 网络学习集中在较小范围内的连接权进行调整, 学习率应随着学习的进行不断减小。一般此阶段的学习速率的初始值选为 0.5。

然而在自组织特征映射网络中, 模拟人脑细胞受外界信息刺激产生兴奋与抑制的变化规律是通过邻域的作用来体现的。邻域规定了与获胜神经元 g 同时进行连接权调整的神经元范围。在学习初始阶段, $N_g(t)$ 包含的范围较大, 一般为竞争层的 1/3-1/2, 甚至可以覆盖整个竞争层。随着学习的深入, $N_g(t)$ 的范围逐渐减小, 最后达到预定的范围。

4.3.2 SOFM 算法在图像压缩中的应用

首先将图像分成 4×4 或者 8×8 的图像子块, 这些图像子块数据将构成训练 SOFM 网络的训练矢量, SOFM 网络的输入矢量的维数由图像子块的大小确定,

分别为 16 维（图像子块的大小为 4×4 ）或者 64 维（图像子块的大小为 8×8 ），网络输出层神经元个数由压缩比和重建图像的质量决定。

SOFM 网络创建以后，对其权值矩阵初始化，即对码书进行初始化，本实验中均匀选取图像子块来初始化。通过训练图像的所有子块来训练初始 SOFM 网络，训练结束，SOFM 网络趋于稳定，由此 SOFM 网络的权值构成矢量量化的最终码书。然后利用得到的最终码书对所有的图像子块进行编码，最后把对应于每一个图像子块的获胜码字矢量的索引号存储到压缩文件中。解码时只要从文件中读出相应的索引号，然后对照码书，用相应的码字矢量代替原来的图像子块，重建图像即可。

图像压缩的整个流程图如下：

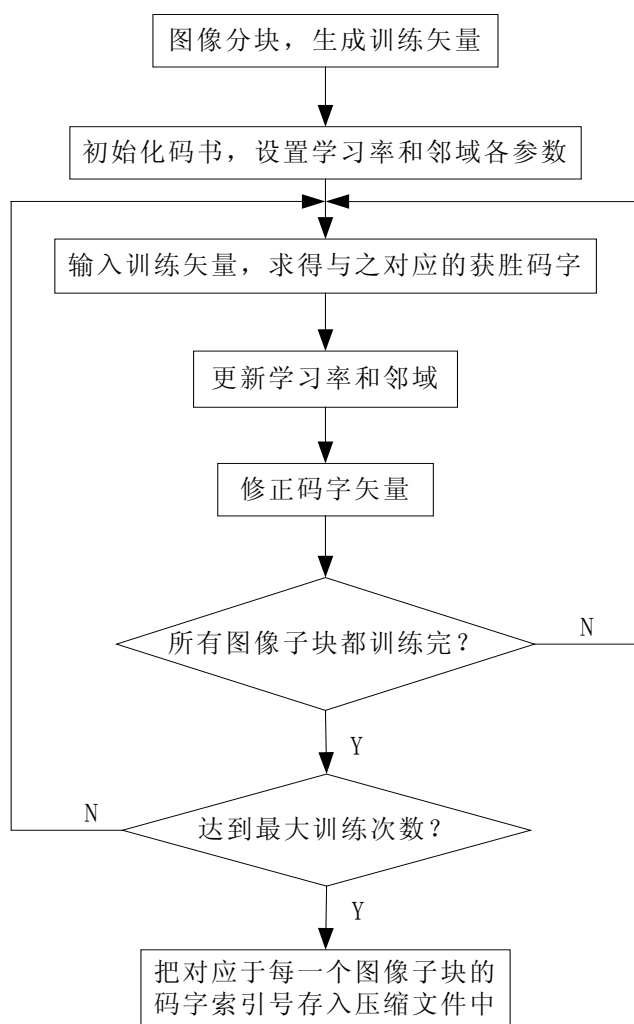


图 4.7 SOFM 图像压缩流程图

Fig4.7 Flow diagram of image compression by SOFM neural network

在仿真实验中，采用的训练图像是 256×256 的 Lena 图像，256 级灰度，原始分辨率为 8 比特/像素。

如同第三章，重建图像的性能用比特率、压缩比、信噪比和峰值信噪比等指标来评价。

这里比特率和压缩比的计算公式分别如下：

比特率 = (比特/块) / (块的大小)，比特/块 = \log_2 (网络竞争层神经元的个数)；

压缩比 = 比特率 / 8 (由于原始图像的分辨率为 8 比特/像素)；

信噪比和峰值信噪比分别与 (3.28) 式和 (3.29) 式相同。

4.4 实验结果及分析

4.4.1 竞争层神经元个数对压缩性能的影响

实验一：在其他参数固定的条件下，通过增加 SOFM 网络中的竞争层的神经元个数来提高重建图像的质量。

学习率与邻域的选择如下：

当 $t < 500$ 时， $\eta(t) = 0.1e^{-t/20}$ ， $N_g(t) = 5 + 495e^{-t/100}$

当 $500 < t < 5000$ 时， $\eta(t) = 0.01e^{-t/10}$ ， $N_g(t) = 1 + 5e^{-t/100}$

在以上前提下，输入矢量为 16 维，竞争层神经元个数（即码书的大小）分别是 2×2 ， 4×4 ， 8×8 和 16×16 ，其重建图像如图 4.8 所示，重建图像的压缩性能见表 4.1。



(a) 竞争层神经元个数 2×2

(a) Neurons of competitive layer 2×2



(b) 竞争层神经元个数 4×4

(b) Neurons of competitive layer 4×4



(c) 竞争层神经元个数 8×8

(c) Neurons of competitive layer 8×8



(d) 竞争层神经元个数 16×16

(d) Neurons of competitive layer 16×16

图 4.8 基于 SOFM 算法的重建图像 (图像子块大小 4×4)

Fig4.8 Reconstructed image based on SOFM algorithm (sub-image size 4×4)

表 4.1 重建图像的压缩性能

Table 4.1 The compression performance of the reconstructed image by SOFM algorithm

码书大小	比特率	压缩比	信噪比	峰值信噪比
2×2	0.125	64	26.5009	43.1162
4×4	0.25	32	35.7838	52.3991
8×8	0.375	21.3	40.6162	57.3150
16×16	0.5	16	43.2622	59.8775

从图 4.8 的各图可以直接看出随着码书的增加重建图像的质量随之逐渐变好，视觉效果也增强了，由模糊变得清晰，方格效应也有所减弱。再者，从表 4.1 可以看出，随着码书大小的增加，每个像素编码需要的比特数增加，因此压缩比降低，然而信噪比和峰值信噪比却不断增加，但是训练时间也随之变长了。综上所述，更高的压缩比是以牺牲重建图像的质量和编码时间为代价的。

4.4.2 训练矢量个数对压缩性能的影响

实验二：用可变训练矢量数目分别训练网络。

将 256×256 的 lena 图像分别分成 4×4 和 8×8 的子块，得到的训练矢量的数目分别为 4096 和 1024 个。实验中，对于大于 4096（1024）个训练矢量的情况采取了重复训练方法，即用同一幅图像反复进行训练。实验表明，训练矢量数目越大，其压缩性能越好；当训练矢量超过一定数目后，其改善效果并不明显。这说明了两点，一是训练矢量数目不能太少，否则码书性能较差；二是训练矢量数目越大，训练时间越长。因此，可适当限制训练矢量数目，以缩短训练时间。

总之，对于给定的矢量维数，码书越大，压缩比越低，重建图像的质量越好，复杂度越大；反之亦然。通常，要综合考虑压缩率、失真率和训练所花费的时间这几个因素，在矢量维数，码书大小和压缩性能之间进行权衡，以满足实际应用。

4.4.3 学习速度与衰减常数对压缩性能的影响

实验三：不同的初始学习速度 $\eta(0)$ 和衰减常数 T_1 对重建图像的性能的影响。

从表 4.2 可以看出：当初始学习速率比较小的时候（ $\eta(0) = 0.001$ ），重建图像的峰值信噪比（PSNR）比较低，而且在某些情况下，还可能出现不收敛的情况。随着 $\eta(0)$ 的增大，重建图像的 PSNR 值也逐渐变大，但是当 $\eta(0)$ 超过某一个值时，PSNR 值又逐渐减小，我们认为这是由于 $\eta(0)$ 太大，而使得在码字矢量的权值修正过程中产生了过调，导致了重建图像 PSNR 值的减小，甚至不能收敛。从表中还可以看出：当初始学习速率的取值在 0.001-0.01 范围内时可以取得较高的 PSNR 值。

图 4.9 显示了学习速度对压缩性能（PSNR）的影响。由图可见，当衰减常数 T_1 较小时， $\eta(t)$ 的值下降太快，使得码书的调整变化幅度下降过急，很难跟踪图像

的统计特性，码书性能不尽人意；当 T_1 较大时， $\eta(t)$ 的值下降很慢，码矢的调整变化幅度较大，很容易跳过网络能量函数的全局极小点。其最佳学习速度参数，即使是使 $PSNR$ 值最大的 T_1 值。

表 4.2 在不同的初始学习速率 $\eta(0)$ 和衰减常数 T_1 下的重建图像的 $PSNR$ 值

Table 4.2 $PSNR$ value of reconstructed image with different $\eta(0)$ and T_1					
	$T_1 = 4$	$T_1 = 8$	$T_1 = 16$	$T_1 = 24$	$T_1 = 32$
$\eta(0) = 0.001$	31.8912	32.3741	32.6125	32.5112	31.9512
$\eta(0) = 0.005$	33.1254	33.3245	33.3651	33.3512	33.2356
$\eta(0) = 0.008$	33.0521	33.6578	33.5452	33.5124	33.3771
$\eta(0) = 0.01$	32.6557	33.4001	33.4652	33.4598	33.4822
$\eta(0) = 0.013$	30.5911	32.5784	32.7744	32.6002	32.8988
$\eta(0) = 0.015$	25.2564	31.3215	32.3458	32.4023	23.8297




图 4.9 学习速度对压缩性能的影响

Fig4.9 Compression performance influenced by learning rate




图 4.10 邻域参数对压缩性能的影响

Fig4.10 Compression performance influenced by neighborhood parameter

4.4.4 邻域参数和初始码书对压缩性能的影响

实验四：用不同的邻域参数训练网络。

图 4.10 给出了邻域参数对压缩性能的影响，从图中可以看出，当 A_2 较小时，SOFM 网络的效果不明显，网络的优点未得到充分利用；而 A_2 很大时，其效果也不佳，这是因为在外界刺激最强（失真最小的码矢）处所形成的 Bubble 区的大小是有限制的，离 Bubble 区越远，则神经元间的相互影响越小，甚至相互抑制。

实验五：用不同的初始码书选择方法来训练网络。

为了观察初始码书选取的效果，应用了两种初始化方案，当创建一个 SOFM

网络后，初始化 SOFM 网络时，采用了随机法、等间隔法和常数法来初始化码书，也即对初始权值可以随机赋值，或者从训练图像的所有子块中均匀选取图像子块来初始化 SOFM 网络的权值矩阵，也可以用[0,1]之间的常数来初始化。实验结果表明，网络初始权矢量值（即码书的初始值）的选择对网络学习过程有很大的影响。实验中，图像子块的大小取为 4×4 ，SOFM 竞争层神经元个数为 8×8 ，训练矢量一共 4096 个；间隔法中每隔 63 个取一个矢量，一共选择 64 个输入矢量来初始化权值矢量；而随机法中用[0,1]之间的随机值作为初始码书；而常数法中给所有初始权值赋 0.5。实验结果见表 4.3。

表 4.3 初始码书对压缩性能的影响

Table 4.3 Compression performance influenced by initialization code book

初始码书选择方法	块的大小	码书大小	比特率	压缩比	信噪比	峰值信噪比
间隔法	4×4	8×8	0.375	21.3	40.6162	57.3150
随机法	4×4	8×8	0.375	21.3	37.5289	54.2997
常数法	4×4	8×8	0.375	21.3	40.3256	56.7725

从表 4.3 可以看出，等间隔法和常数法的效果好于随机法，能在一定程度上加快网络的收敛过程，对重建图像的信噪比和峰值信噪比有一定改善。这主要是因为等间隔法的初始码矢是从训练矢量中按照一定间隔选取的，接近输入矢量集的分布；而常数法也能较快地强迫码书作调整。

4.5 本章小结

本章在深入研究矢量量化与自组织特征映射网络的基础上，探讨了自组织特征映射网络在矢量量化方面的应用，由于该网络采用的是无监督学习算法，它能对输入数据进行综合、归纳和统计，从而使之能够自适应响应不同信号模式，因此该网络用于图像压缩具有很大的优势，本章利用自组织特征映射网络的这些特性实现矢量量化，它能有效地克服用于矢量量化中的 LBG 算法的两大缺点：一是对初始码书敏感，二是训练时间长且存在无效码矢。

另外，本章具体分析了用自组织特征映射网络实现矢量量化的方法和流程，并且从不同的角度研究算法中各参数对压缩性能的影响，主要有竞争层神经元个数、训练矢量个数、学习速度与衰减常数以及邻域参数与初始码书等几个方面，通过大量实验验证了 SOFM 图像压缩是可行的。

5 基于 Hopfield 网络的边缘检测和边缘保持的 SOFM 图像压缩

虽然矢量量化具有高效压缩和解码迅速的优点,但是传统的矢量量化方法存在自身无法克服的缺陷:(1)早期的 LBG 算法用于码书设计时,对初始码书十分敏感,并且在训练中存在无效矢量和训练时间长的缺点;(2)恢复图像质量时存在明显的方块效应;(3)图像细节、边缘部分失真严重;(4)编码时间长,传统的穷尽搜索运算复杂度高,搜索速度慢,限制了矢量量化的实时应用。为了克服这些传统的矢量量化方法的不足,近年来,许多学者在这方面进行了有益的探索和改进。作者针对第三点缺陷提出了基于人工神经网络的图像边缘保持矢量量化方法,其中图像的边缘检测部分抛弃了传统的边缘检测方法,而使用 Hopfield 网络实现边缘检测,由此计算出的图像边缘的细节参数可以灵活调解,将这些参数合理用在 SOFM 矢量量化的权值调整系数中,从而实现了图像边缘保持矢量量化,这是基于神经网络的图像压缩方法的一种新的尝试,也是本论文的创新和闪光之处。

本章主要讨论 Hopfield 神经网络的算法模型、基于 Hopfield 神经网络的图像边缘检测的原理及实现,以及改进的 SOFM 图像压缩方法的原理及实现。

5.1 Hopfield 网络研究^[8]

Hopfield 神经网络模型是由美国加州工学院物理学教授 Hopfield 于 1982 年提出的一种全互连接的反馈型神经网络。由于网络中成功地引入了“能量函数”的概念,给出了网络的稳定性判据,所以可以用它来实现 A/D 转换和解决优化组合计算等问题。所有这些有意义的成果有力地推动了神经网络的研究热潮,开拓了神经网络在信息处理和优化计算中的新用途。Hopfield 神经网络模型有离散型和连续型两种,而本文中图像边缘检测用的是离散型。

Hopfield 神经网络是一种反馈型神经网络,反馈型神经网络是一个非线性动力学系统,它具有如下两个重要特征:(1)系统具有多个稳定状态,从某一初始状态开始运动,系统最终可以达到某一个稳定状态;(2)不同的初始权值对应的稳定状态也不相同。如果用系统的稳定状态作为记忆,那么由某一初始状态出发向稳态的演化过程,实际上就是一个联想过程,所以 Hopfield 神经网络具有理想记忆功能。实际上,它的解并不需要真正去计算,而只要构造这种反馈神经网络,适当地设计其连接权和输入就可以达到这个目的。

5.1.1 离散型 Hopfield 网络及其稳定性分析

由 N 个神经元构成的 Hopfield 网络结构如图 5.1 所示。在离散型 Hopfield (DHNN) 模型中, 每个神经元只取二元的离散值 0 或 1, 神经元的状态变化规则与 MP 模型相同, 即

$$x_i = \begin{cases} 1, & \sum_{j \neq i} w_{ij} x_j - \theta_i > 0 \\ 0, & \sum_{j \neq i} w_{ij} x_j - \theta_i \leq 0 \end{cases} \quad (5.1)$$

神经元的状态更新采用串行异步工作方式, 即在任一时刻 t , 只有一个神经元的状态在发生变化, 其它神经元的状态保持不变。且规定 $w_{ij} = w_{ji}$, $w_{ii} = 0$, 即 DHNN 采用无自反馈的对称连接。如果网络在某一时刻以后状态不再发生变化, 则认为该网络处于稳定状态。下面从能量的观点来说明当满足上述条件时, 若网络按串行异步方式更新状态, 则网络必收敛于状态空间的某一稳定状态。

设 Hopfield 网络的能量函数为

$$E = -\frac{1}{2} \sum_i \sum_{j \neq i} w_{ij} x_i x_j + \sum_i \theta_i x_i \quad (5.2)$$

式中, x_i , x_j 是第 i , j 个神经元的输出。若其中第 m 个神经元的输出由 0 变成 1, 则 (5.1) 式可知

$$\sum_{j \neq m} w_{mj} x_j - \theta_m > 0 \quad (5.3)$$

设变化前 ($x_m = 0$) 网络的能量函数 E_1 为

$$\begin{aligned} E_1 &= -\frac{1}{2} \sum_i \sum_{j \neq i} w_{ij} x_i x_j + \sum_i \theta_i x_i \\ &= -\frac{1}{2} \sum_{i \neq m} \sum_{j \neq i, m} w_{ij} x_i x_j + \sum_{i \neq m} \theta_i x_i - \frac{1}{2} \sum_{j \neq m} w_{mj} x_m x_j + \theta_m x_m \\ &= -\frac{1}{2} \sum_{i \neq m} \sum_{j \neq i, m} w_{ij} x_i x_j + \sum_{i \neq m} \theta_i x_i \end{aligned} \quad (5.4)$$

变化后 ($x_m = 1$) 网络的能量函数 E_2 为

$$\begin{aligned} E_2 &= -\frac{1}{2} \sum_i \sum_{j \neq i} w_{ij} x_i x_j + \sum_i \theta_i x_i \\ &= -\frac{1}{2} \sum_{i \neq m} \sum_{j \neq i, m} w_{ij} x_i x_j + \sum_{i \neq m} \theta_i x_i - \frac{1}{2} \sum_{j \neq m} w_{mj} x_m x_j + \theta_m x_m \end{aligned}$$

$$= -\frac{1}{2} \sum_{i \neq m} \sum_{j \neq i, m} w_{ij} x_i x_j + \sum_{i \neq m} \theta_i x_i - \frac{1}{2} \sum_{j \neq m} w_{mj} x_j + \theta_m \quad (5.5)$$

能量函数 E 的变化量 ΔE 为

$$\Delta E = E_2 - E_1 = -\left(\frac{1}{2} \sum_{j \neq m} w_{mj} x_j - \theta_m\right) \quad (5.6)$$

此时，因为 m 神经元的状态是由 0 变为 1，由 (5.3) 式可知 (5.6) 式括号内的差为正值，所以 $\Delta E < 0$ 。然而，若神经元的状态是由 1 变为 0，也可以证明能量函数的变化仍为 $\Delta E < 0$ 。也就是说，当任意一个神经元状态发生变化时，能量函数都将减小，或者说神经网络在状态变化的过程中，能量函数总是单调下降的。即有

$$\Delta E = \Delta x_i \frac{\partial E}{\partial x_i} = \Delta x_i \left[\sum_{j \neq i} \left(-\frac{1}{2} w_{ij} x_j\right) + \sum_i \theta_i \right] \leq 0 \quad (5.7)$$

由于 E 是有界的，所以系统最后必趋于稳定状态，并对应于在 X 状态空间的某一个局部极小值，如图 5.2 所示。适当地选取初始状态，网络状态最终将演化到初始状态附近的极小值。如果贮存的样本正好对应于极小值，则意味着当输入与贮存样本相似的样本时，会联想起极小值处的贮存样本，所以 Hopfield 网络具有理想记忆功能。




图 5.1 Hopfield 网络结构图

Fig5.1 Hopfield neural network structure




图 5.2 状态 x 的演化

Fig5.2 The evolution of the status x

5.1.2 连续型 Hopfield 网络及其稳定性分析

连续型 Hopfield 网络（以下称 Hopfield 网络）是一种全互连的反馈网络，它具有丰富的非线性动力学特征^[60,61]，特别是 Hopfield 不仅给出了该网络的数学模型，而且还提供了与其相对应的电路模型，这就为它的研究和应用带来了极大的

方便。这里，我们将讨论 Hopfield 网络的有关特性，尤其是与它的稳定性相关的一些内容。

为了分析的方便，先从 Hopfield 网络的电路模型入手，该模型所用到的器件均是常见的模拟电路元件如电阻（电导）、电容和运算放大器等，网络的电路模型如图 5.3 所示。

由图可知，在 Hopfield 网络中，神经元的驱动分为两部分：电流源 I_i 和来自其他神经元的电流 I_{ij} ， u_i 为神经元的输入， V_i 和 $-V_i$ 为神经元的输出。整个网络模型中各个部分的含义分别为：电阻 R_i 和电容 C_i 并联，模拟生物神经元输出的时间特性；神经元之间的跨导 T_{ij} 模拟神经元之间的突触连接特性；运算放大器模拟神经元细胞体的非线性转移特性。在连接方式上，Hopfield 网络的结构具有以下特点：

(1) 连接的对称性，两个神经元之间输出到输入的互连跨导相等，也就是说 $T_{ij} = T_{ji}$ 。值得注意的是，这里的相等不仅意味着数值的相等，而且表示连接的正负极也相同。

(2) 连接的兴奋/抑制特性可以由输出进行调整，因为神经元具有一对幅值相等的正负输出。




图 5.3 Hopfield 网络的电路模型

Fig5.3 Circuital model of Hopfield network




图 5.4 Hopfield 网络的数学模型

Fig5.4 Mathematical model of Hopfield network

参照以上电路模型，可以给出 Hopfield 网络的数学模型，如图 5.4 所示，设神经元的个数为 N ，则它的动力学微分方程为：

$$C_i \frac{du_i}{dt} = \sum_{j=1}^N T_{ij} V_j - G_i u_i + I_i \quad (5.8)$$

$$V_i = g(u_i) \quad (5.9)$$

$$G_i = \frac{1}{R_i} + \sum_{j=1}^N |T_{ij}| \quad (5.10)$$

从这个数学模型可以看出, Hopfield 网络对于生物神经系统的模拟重点突出了以下几点:

- (1) 神经元的传输具有 Sigmoid 特性;
- (2) 神经元通过微分延迟具有时空整合功能;
- (3) 反馈连接是调节神经元状态的主要手段;
- (4) 神经元的活动既能够体现动作电位的工作方式, 又能够体现渐进的工作方式。

可见, Hopfield 网络准确地保留了动态性和非线性这两个在生物神经系统中普遍存在的十分重要的计算特性, 它很好地阐明了神经元如何通过协同作用而产生出强大的计算能力。

对于 Hopfield 网络, 可以用如下方法定义它的能量函数:

$$E = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N T_{ij} V_i V_j - \sum_{i=1}^N V_i I_i + \sum_{i=1}^N G_i \int_0^{V_i} g^{-1}(V) dV \quad (5.11)$$

其中, $g^{-1}()$ 是 $g()$ 的反函数。

定理 5.1 对于 Hopfield 网络, 若满足以下条件:

- (a) $C_i > 0$; (b) $T_{ij} = T_{ji}$; (c) $g^{-1}()$ 单调递增且连续

则有 $\frac{dE}{dt} \leq 0$, 当且仅当对所有的 V_i 都满足 $\frac{dV_i}{dt} = 0$ 时, $\frac{dE}{dt} = 0$ 。

证明见附录 B。

这个定理告诉我们, Hopfield 网络的运行随着时间的推移, 其能量在不断减小, 由此可得如下推论。

推论 5.1 Hopfield 网络的稳定平衡点就是其能量函数的极小点。

此外, 还可以证明, 以下结论对于 Hopfield 网络成立。

- (1) 从任意点出发, 网络将最终趋向某个平衡状态;
- (2) 网络存在有限个平衡点;
- (3) 通过学习, 网络能够将任何一组正交矢量存储起来作为平衡点;
- (4) 网络以非线性连续并行方式处理信息, 其计算时间就是系统趋向稳定状态的时间。

前面所说的稳定性针对的是 Hopfield 网络的输出 V_i , 在本文中将这种稳定状态称为外部稳定 (或称为 V 稳定)。

从 Hopfield 网络的电路模型可知, 神经元输出 V_i 是输入 u_i 经过运算放大器转移的结果。一般来说, 运算放大器的输出具有一定的幅值限制, 也就是说, 不论 u_i 如何变化, V_i 的值总是处于某一个范围内。从另一个角度看, 运算放大器的输入接收范围也不是无限的, 输入同样被要求限定在一定的区间里。 V 稳定虽然保证

了网络输出的稳定性，可是，对于网络输入的变化过程并没有给予任何回答。为了研究这个问题，本文提出了另一个稳定性的概念——Hopfield 网络的内部稳定（或称为 u 稳定）。

定义 5.1 设 $(u_1, u_2, \Lambda, u_N)^T$ 为 Hopfield 网络的一个输入状态，如果对任意 $u_i (1 \leq i \leq N)$ ，均有 $\frac{du_i}{dt} = 0$ ，则称 $(u_1, u_2, \Lambda, u_N)^T$ 为网络的内部稳定状态（ u 稳定状态）。

定理 5.2 在定理 5.1 的基础上，若 $g()$ 进一步满足有界性的条件，则当 Hopfield 网络处于 u 稳定时，它一定处于 V 稳定。

证明见附录 B。

这个定理表明， u 稳定是比 V 稳定更加严格的一种稳定状态，从 Hopfield 网络的电路模型来看，这个理论很容易理解。

定理 5.3 在定理 5.1 的条件下，Hopfield 网络可以到达 u 稳定状态。

证明见附录 B。

至此，本文已经清楚地分析了 Hopfield 网络外部和内部的稳定性问题以及它们之间的关系，这些可以用以下一句话进行总结：“在一定条件下，Hopfield 网络一定能够到达 V 稳定状态和 u 稳定状态，并且 V 稳定状态来的时候总是不晚于 u 稳定状态。”

以上介绍了经典的 Hopfield 网络结构及其原理，下面讨论用改进的 Hopfield 网络实现图像边缘检测。

5.2 用改进的 Hopfield 网络实现图像边缘检测

利用计算机进行图像处理有两个目的：一是产生更适合人观察的图像；二是能由计算机自动识别和理解图像。无论为了哪种目的，图像处理中关键的一步是对包含有大量景物信息的图像进行分解，提取一些具有某种特征的图像信息。图像的边缘是图像最基本的特征之一。所谓边缘是指其周围像素灰度有阶跃性变化或屋顶变化的像素的集合。

图像的特征提取的发展主要分为两个分支：其中之一来自计算机视觉领域；另一个分支主要是基于空间域某一函数的一阶或者二阶导数，为了找到图像的重要特征就必须检测出一阶导数的最大值点或者二阶导数的过零点。常用的边缘检测方法^[62]有：Roberts、Sobel、Prewitt、Krisch、Gauss-Laplace 边缘检测算子及轮廓提取或轮廓跟踪、利用平滑技术检测图像边缘、利用差影技术检测图像边缘、利用小波分析技术检测图像边缘。

然而本文提出一种新的边缘检测方法，基于人工神经网络的图像边缘检测方法，通过不断的学习来找到图像的重要特征。文献[63]用遗传 BP 网络进行图像边缘检测，它是一种有监督的学习算法，文献[64]则使用了竞争模型实现边缘检测。而另外一方面，如果在没有任何先验知识的前提下，能开发出一种无监督的神经网络模型、选择恰当的传输函数来检测灰度图像的边缘，那将是另一种很有意义的尝试。因此，本文运用一种改进型 Hopfield 网络来执行无监督多级边缘检测。

5.2.1 改进后的 Hopfield 网络及其算法

图 5.5 给出了改进后的 Hopfield 神经网络模型，该网络具有 N 个神经元，而且是单层结构，各个神经元之间相互连接，因此网络的权值矩阵 W 的大小是 $N \times N$ 。




图 5.5 用于图像边缘检测的 Hopfield 网络模型

Fig5.5 Hopfield neural network structure applied in edges detection from images

该网络中运用的传输规则是双极型 signum 函数，其表达式如下：

$$x_{t+1} = \text{sgn}[Wx_t], \quad t = 1, \Lambda, T \quad (5.12)$$

$$\text{sgn}[a] = \begin{cases} a = 1, & a > 0 \\ a = -1, & a < 0 \\ a = 0, & a = 0 \end{cases} \quad (5.13)$$

x 表示输入矢量， a 是激活函数，这里 $a = Wx_t$ 。

这里不能使用原始的 Hopfield 学习规则的原因在于原始的学习规则无边界。因此，通过学习成千上万个不同的模式，网络最终只能得到一个特征值，不能完成边缘检测任务。为了克服原有模型的这个局限性，Chartier 和 Proulx^[65]提出下面的学习规则：

$$W_{k+1} = W_k + \eta[x_0 x_0^T - (W x_m)(W x_m)^T] \quad (5.14)$$

式中, $\eta(\eta > 0)$ 代表学习系数和 x_0 表示输入矢量, x_m 是 x_0 经过 m 次迭代后的状态矢量。与原有的 Hopfield 网络不同的是: 这种运算规则是重复迭代的, 并且通常收敛于权值矩阵的伪逆。因此, 该学习算法容许存储容量的增加, 而且更好的定义了吸引子。

5.2.2 网络的训练步骤以及学习机理分析

本文选择 256×256 的 Lena 图像作为标准灰度图像来做实验。为了训练网络, 首先将原始图像分成 3×3 的互不重叠的像素块, 并将每一小块变形为 9×1 的列向量, 就这样从原始图像中提取出 7396 个 3×3 的图像子块, 原始图像数据块就变成了 9×7396 的矩阵, 每一个列矢量作为一个输入模式。由于原始图像是 8 位灰度图像, 像素值是 $[0, 255]$, 为了加快网络的训练速度, 我们将各像素值归一化到 $[-1, 1]$ 。完成图像预处理后, 根据下面的步骤训练网络和仿真。

- (1) 初始化权值($W_{ij} = 0$)、初始化学习系数 ($\eta = 0.01$) 和迭代次数 ($m = 10$);
- (2) 随机选择输入矢量 x_0 ;
- (3) 根据 (5.12) 式和 (5.13) 式反复迭代, 得到 x_m ;
- (4) 根据 (5.14) 式修改权值;
- (5) 重复 2 到 4 步 2000 次。

训练结束后, 对权值矩阵进行奇异值分解。

图 5.6 显示了权值矩阵的特征值频谱, 图中的 9 个特征值分别是: 0.52824, 0.44282, 0.4135, 0.19397, 0.1562, 0.091168, 0.065072, 0.044104, 0.027833, 其中有三个重要的特征值。




图 5.6 权值矩阵的特征值频谱

Fig5.6 Eigenvalues spectrum of the weight matrix

第一个特征值代表分布平均值, 不能给出特殊的提示; 然而第二个和第三个

特征值则起到了判别函数的作用，通过可视化这两个特征值所对应的特征向量可以帮助理解潜在的聚类过程。从图 5.7 中可以看出第二个特征向量相当于一个水平边缘检测器，第三个特征向量相当于垂直方向的边缘检测器。



图 5.7 第 2 和第 3 个特征向量的密度平面图

Fig5.7 Density plot of eigenvector number 2 and 3

下面给出这两个特征向量的实际值，从中可以看出它们的实际功能相当于典型的普鲁伊特（Prewitt）微分算子^[62]。

$$\begin{pmatrix} -0.4504 & -0.4646 & -0.4280 \\ -0.0014 & 0.0191 & 0.0052 \\ 0.3576 & 0.3221 & 0.3370 \end{pmatrix} \quad \begin{pmatrix} 0.3734 & -0.0918 & -0.4906 \\ 0.3847 & 0.0995 & -0.4668 \\ 0.3813 & 0.0881 & -0.4508 \end{pmatrix}$$


与 Prewitt 算子不同的是：这种模型的传输规则使用的是非线性过程，对这个非线性过程进行学习就能实现边缘检测回想过程。

5.2.3 边缘检测以及结果分析

测试网络之前，必须弄清楚网络到底怎样判断边缘存在或者不存在。首先，网络输出的是 9×1 的矢量，就是 3×3 的图像子块的仿真结果。当有边缘存在时，最后输出为“1”，相反，边缘不存在时，输出为“0”。鉴于此，我们将网络的输出矢量连接到一个求和单元。求和后如果输出值为 9 或者 -9，即神经网络的输出矢量的每个分量同为 1 或者 -1 时不存在边缘，否则存在边缘。因此，用下面的表达式来完成这个步骤。

$$c(x) = \begin{cases} 0, & \text{if } \sum x_j = 9 \text{ or } \sum x_j = -9 \\ 1, & \text{else} \end{cases} \quad (5.15)$$

当且仅当网络检测到图像的边缘时，最后的输出才是 1。用 Lena 图像测试网络进行边缘检测，其检测结果如图 5.8 所示，其中 (a) 图是原始图像，(b) 图是基于 Hopfield 网络边缘检测结果。



(a) 原始图像

(a) Original image



(b) Hopfield 网络边缘检测

(b) Illustration showing edges of (a)

图 5.8 Lena 原始图像与边缘检测

Fig5.8 Image Lena and its edges

从 (b) 图来看, 网络并没有检测出所有重要的边缘, 比如帽穗的细节根本都没有检测出来。实际上, 网络只能检测出白色背景下的黑色物体, 比如说白色墙壁上的窗户, 即对比强烈的边缘, 该网络不容易检测出灰色背景中的灰色物体的边缘, 比如说长在草地中的一棵树, 对于这种对比不强烈的图片, 该网络不能检测出物体的边缘。从神经网络的理论角度来说, 如果有两个像素值相近的物体, 比如像素值为 0.6 的草和生长在草地中间的一棵像素值为 0.8 的树, 这两个值都在同一个吸引子的吸引区, 因此他们相互的区别并不明显, 所以无法检测出这样的边缘。


5.2.4 输入矢量的整定以及仿真结果

为了克服上面提到的缺陷, 必须在测试之前对输入矢量进行重新整定。这个整定过程又是一个迭代过程, 它可以使网络在某时刻只关注像素值的一个小的范围。这可以用下面的函数来实现。

$$x_t = x_0 - 1 + s \times t \quad (5.16)$$

式中 x_t 代表整定后的输入值, $s(0 < s \leq 1)$ 为整定步长, t 是离散时间变量 (t 从 0 到 $2/s$)。例如, 如果取 $s = 0.2$, 则参数 t 应该取 0, 1, ..., 10。这样相同的输入矢量就分 11 次表示, 每一次都来自不同的整定点。

不过为了得到最后的边缘图像, 必须将各个整定点的图像求和再取平均。我们仍然用 Lena 图像测试网络, 运用上述的处理方法, 取 $s = 0.2$, 得到各个时间步的边缘图像用以对比。图 5.9 显示了经过重新整定输入后的各个时间步的检测结果以及均值后的边缘图像。

图 5.9 整定函数中的不同时间步 t 对应的边缘图像Fig5.9 Images obtain after edge detection in function of the time step t

从图 5.9 可以看出经过整定处理后网络的注意力只集中在一个小范围内, 其中 (f) 图的效果与图 5.8 中的 (b) 图完全相同, 其原因是非常明显的, 将 $t = 5$ 带入 (5.16) 式就知道其实这时根本没有对输入进行重新整定, 所以网络回想过程不变。

图 5.9 中的 (1) 图显示了将 11 次检测图像求和再均值后的边缘图像。从中可以看出原始图像中更多的边缘被检测出来。通过选择聚焦的小范围，神经网络检测出很多不重要的边缘，从而加大了进一步处理图像的难度，从某种意义上说这样的边缘检测是没有实际意义的，因此必须加以改进。为了克服这个难点和不足，下面增加阈值处理环节。

5.2.5 阈值处理以及仿真结果

理想的阈值必须随着图像不同而灵活变化，并且与时间步相关。为了达到这些要求，可以使用下面的表达式计算最后输出值。

$$y = \begin{cases} 1, & \text{if } \sum_{t=0}^{2/s} x_t > 2/s - \theta \\ 0, & \text{else} \end{cases} \quad (5.17)$$

式中， $\theta (\theta \geq 0)$ 是阈值系数，选择 $\theta = 2$ ，并将上一节的实验结果带入 (5.17) 式，网络输出就只保留那些有意义的轮廓。图 5.10 是加阈值处理后的边缘检测结果。



图 5.10 阈值处理后的边缘图像

Fig5.10 Edges from Image using a threshold

至此，我们得到了理想的边缘检测结果，下面利用边缘检测结果计算原始图像的边缘统计特性，再将其融入到 SOFM 的权值修正过程中，从而实现边缘保持的 SOFM 矢量量化。

5.3 边缘保持的 SOFM 图像压缩

重建图像边缘失真严重的原因主要有以下几个方面：由于图像的边缘信息只占图像总量中的很小一部分，因此，在利用第四章所述的 SOFM 算法产生的码书中，必然只包含一小部分的边缘矢量；另外，我们是采用均方误差作为“失真测度”的，而均方误差并不具有保持边缘信息的能力，也就是说，对于任一输入矢量（边缘区或非边缘区）的“失真测度”是相同的，因此，这些均造成了重建图像的边缘失真严重，甚至产生锯齿效果。针对这种现象，K.Y.Kin 和 J.B.Ra 早在

1993 年就提出了基于自适应算法的图像边缘保持矢量量化方法^[66,67]，他们主要是根据图像的锐度和复杂度计算图像子块的权值因素，并自适应的调整权值，从而达到边缘保持的效果。本文提出另外一种图像边缘保持的矢量量化方法，根据图像子块的边缘像素的统计特性来计算权值因素，下面论述这种方法的具体步骤。

5.3.1 改进的自适应学习方法

自组织特征映射的中心目标就在于：神经元中突触内联权矢量试图模仿输入信号，这是一个无监督的学习过程，根据式 (4.6)，常规 SOFM 方法学习参数仅仅是时间的递减函数，而与输入矢量（图像子块）的统计特性无关，由上述边缘失真的原因分析可见，为了改善重建图像的边缘信息，在码书的训练过程中，权值的调整应尽可能的考虑输入训练矢量（图像子块）的统计特性。

本文提出的边缘保持自适应学习方法的基本思想是：在训练过程中，对每一图像子块 i 分配一个“活跃因子” $\beta_i(\sigma)$ ， $i=1,2,\Lambda,N$ ， N 为图像子块个数。该“活跃因子”是图像子块的统计特性（边缘、纹理）的函数，反映了图像子块对人的视觉系统的灵敏程度，也称为图像的“活跃测度”。将 $\beta_i(\sigma)$ 与原学习参数 $\eta(t)$ 相结合，形成一个新的可变的学習参数，即不同的训练矢量（图像子块）有不同的学习参数。引入这种“活跃因子” $\beta_i(\sigma)$ 的结果是：通过分析输入图像子块的统计特性，划分出边缘子块和非边缘子块，从而自适应改变学习参数，其具体过程如下：

首先应用本章的 5.2 节中介绍的方法对整幅图像进行边缘提取，每一图像子块的“活跃因子”可由下式决定：

$$\beta_i(\sigma) = \frac{\beta_{\max} - \beta_{\min}}{\sigma_{\max}^2} \times \sigma_i^2 + \beta_{\min}, \quad i=1,2,\Lambda,N \quad (5.18)$$

式中， N 为子块个数， σ_i 为第 i 个图像子块所包含的边缘像素个数， σ_{\max} 为子块中包含的最大边缘像素个数（即 σ_i 的最大值）， β_{\max} 和 β_{\min} 分别为图像子块“活跃因子”的最大值和最小值，可以通过选择 β_{\max} 和 β_{\min} 的值来控制“活跃因子”的变化范围。

由上述图像子块含有的边缘信息决定的“活跃因子”可以看作输入训练矢量（图像子块）在一次迭代中出现的次数。例如，假定某一图像子块 i 的“活跃因子”为 2.6，并设最佳匹配（获胜）神经元为 c ，则输入矢量可看作已出现 2.6 次，一次迭代过程如下：

- (1) 将“活跃因子”减 1，即 $\beta'_i(\sigma)=1.6$ ，按照下式调整码矢 c 即 c 的拓扑邻域 $N_c(t)$ 内的码矢，即：

$$W_c^1(t) = W_c(t) + \eta(t)[X_i(t) - W_c(t)] \quad (5.19)$$

(2) 因为 $\beta'_i(\sigma) = 1.6$ 仍然大于 1，继续将“活跃因子”减 1，即 $\beta''_i(\sigma) = 0.6$ ，调整算法仍为：

$$W_c^2(t) = W_c^1(t) + \eta(t)[X_i(t) - W_c^1(t)] \quad (5.20)$$

(3) 因为此时“活跃因子”只剩 0.6，小于 1，则最后码矢调整为：

$$W_c(t+1) = W_c^2(t) + 0.6\eta(t)[X_i(t) - W_c^2(t)] \quad (5.21)$$

下图中的图 (a) (b) (c) 分别是式 (5.19) (5.20) (5.21) 的几何表示。




图 5.11 基于“活跃因子”的权值矢量调整的几何表示

Fig5.11 Geometric denotation of weight value being modified based on ‘activity factor’

将式 (5.19)、式 (5.20) 和式 (5.21) 推广到一般形式，则有：

$$W_c(t+1) = W_c(t) + \eta_{eff}(t)[X_i(t) - W_c(t)] \quad (5.22)$$

$$\text{其中, } \eta_{eff}(t) = \eta_g(t) + [\beta_i(\sigma) - g]\eta(t) \times [1 - \eta_g(t)] \quad (5.23)$$

$$\eta_q(t) = \eta_{q-1}(t) + \eta(t) \times [1 - \eta_{q-1}(t)] \quad (5.24)$$

这里 g 是 $\beta(\sigma)$ 的整数部分， $q = 1, 2, \Lambda, g$ 且 $\eta_0(t) = \eta(t)$ 。

因此，当 $0 < \eta(t) < 1$ 时，有效学习参数 $\eta_{eff}(t)$ 总是小于 1，以保证算法的收敛。若“活跃因子” $\beta_i(\sigma) = 1$ ，则上述过程简化为常规 SOFM 学习算法，其学习参数仍为 $\eta(t)$ 。

从以上分析可以看出，通过对图像子块所含的边缘信息分析，自适应地调整训练矢量的学习参数，以达到最大程度的保持重建边缘信息的效果，模拟实验证明了这种方法的可行性。

5.3.2 基于 SOFM 网络的边缘保持矢量量化系统

图 5.12 所示的是基于 SOFM 网络的边缘保持矢量量化 (EPVQ) 系统的原理框图，从图中可以看出，系统先对输入图像进行边缘检测，再累计每一图像子块的边缘像素个数 σ_i ，并通过比较器找出子块中包含的最大边缘像素个数 σ_{\max} ，从而由式 (5.18) 确定每一训练矢量 (图像子块) 相对应的“活跃因子” $\beta_i(\sigma)$ ，(其中 $i = 1, 2, \Lambda, N$)，使得系统在利用 SOFM 算法进行码书训练过程中，对具有不同统计特性的输入训练矢量 (图像子块)，按式 (5.22) 自适应地调整学习参数，从

而尽可能减小图像的边缘失真，提高重建图像的质量。

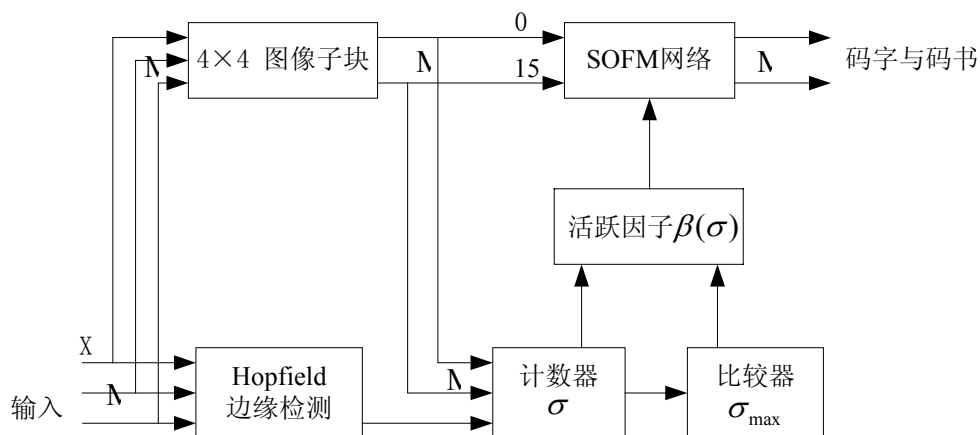


图 5.12 EPVQ 系统原理框图

Fig5.12 Schematic diagram of EPVQ system

5.3.3 实验结果

本实验按照图 5.12 所示的 EPVQ 系统对标准样本图像 Lena (256×256) 进行了矢量量化，在实验中，取 4×4 的图像子块，且码本尺寸为 256，用地址表示为 8bits。编码后图像的比特率为 0.5bit/pixel。图 5.13 展示了用原始的 SOFM 矢量量化和边缘保持 SOFM 矢量量化后的重建图像。

从 (b) 图可见，基于 EPVQ 系统的重建图像的边缘基本保持了原图的边缘信息，与 (a) 图相比，(b) 图具有更好的边缘特性和视觉效果。另外，表 5.1 给出了两种方法编码图像的客观指标：信噪比 (SNR) 和峰值信噪比 (PSNR)。



(a) 基于原始 SOFM 矢量量化



(b) 基于 EPVQ 系统

(a) Based on the original SOFM VQ

(b) Based on the EPVQ system

图 5.13 重建图像

Fig5.13 The reconstructed images

表 5.1 图像编码的客观指标

Table 5.1 The compression performance of image

	Bit rate(bites/pixel)	PSNR(dB)	SNR(dB)
SOFM VQ	0.5	35.14	31.23
EPVQ	0.5	37.52	32.85

因此,从实验结果看,基于 EPVQ 系统实验的译码图像边缘质量在同一压缩比下无论从客观指标还是主观视觉效果来看,都比单纯用 SOFM 矢量量化的效果好。

5.4 本章小结

本章提出的基于 Hopfield 网络的图像边缘检测方法利用了 Hopfield 网络的并行结构,提高了计算速度,并且改进后的算法实现了基于内容的边缘检测,这是本文的一个创新之处,也是一种新颖的算法应用和全新的尝试过程。另外利用边缘检测结果对图像的边缘像素进行统计计算,从而得到图像子块的边缘统计特性。进一步将这种特性融入 SOFM 矢量量化的权值修改过程中,改进后的边缘保持 SOFM 矢量量化方法,不仅克服了原始的 SOFM 矢量量化以及 BP 网络图像压缩的缺点(如预分类产生的图像失真等),而且对于提高译码图像边缘质量有明显的改进作用。另外,本系统是完全利用人工神经网络构成,在并行处理器中运算速度得到了很大的提高,这是本文最有研究价值的地方。

6 总结与展望

6.1 本文总结

本文根据图像像素数据的相关性,利用人工神经网络这一先进技术,经过自适应调整和学习去除相关性,最终达到压缩图像数据的目的。

归纳起来,本文主要取得了以下成果和创新:

(1) 深入研究和对比分析了传统的图像压缩方法和新型图像压缩方法,对这两类方法的利弊都作了全面而深入的讨论,总结了神经网络的自身特点以及它在图像压缩领域应用的优势,并对其进行可行性分析。

(2) 在深入研究和探讨 BP 网络的模型以及算法的基础上,剖析基于 BP 网络的图像压缩的机理,并应用单个细腰型的 BP 网络实现了图像压缩,而且在一系列实验的基础上,分析和总结了压缩比、学习算法、传输函数、信噪比、训练时间以及峰值信噪比之间的关系,这是本论文工作的一个主要部分。

(3) 在第二点的基础上,结合图像块间的相关性,提出了多级 BP 网络实现图像压缩的思想,分析了基于多级 BP 网络的图像压缩的网络模型,深入研究了多级网络的嵌套式训练算法,从而在现有条件下实现了图像压缩与图像重建工作,这是本论文的一种尝试。

(4) 研究了自组织特征映射网络(SOFM)的算法以及结构,探讨了矢量量化的有关理论,并在此基础上分析 SOFM 在矢量量化中的应用及其关键技术,最后用 SOFM 实现矢量量化,从而实现图像压缩,并分析各种参数对重建图像性能的影响,这也是本论文的主要工作之一。

(5) 本文的创新之处在于用 Hopfield 网络进行图像边缘检测,这与传统的图像边缘检测方法完全不同,利用 Hopfield 网络的并行结构,提高了计算速度,并且实现了基于图像内容的边缘检测。

(6) 基于本文的重点研究对象——图像压缩,运用边缘检测结果计算出图像子像素块的统计特性和边缘特性,并将其融入自组织特征映射网络的权值修正过程中,从而提出了一种边缘保持的 SOFM 矢量量化方法,实验证明该方法是行之有效的,与改进之前的 SOFM 图像压缩方法的重建图像相比,该方法的重建图像的边缘更加清晰,其信噪比和主观视觉效果均有所提高。这种方法的提出是本论文的主要创新之处。

6.2 工作展望

本课题的研究使我深切地感受到该课题的挑战性。尽管神经网络理论引入图像压缩编码的某些领域的研究工作进展顺利，成果屡有报道，但离人们对这种图像编码新方法的期望还相差甚远，可以说基于神经网络的图像编码方法的研究仍处于一个初级阶段，还未取得重大的突破性进展，原因很多，主要存在以下几个方面：

(1) 多层 BP 模型用于非线性非正交变换编码的压缩机理还不清楚。虽然我们试图用多层 BP 网络学习某种未知映射，使之逼近最佳映射 KLT，然后用于所有图像信源的变换编码，但从定性的角度来分析，这种想法还存在一定的问题。因为图像信源的最佳映射与信源本身的固有特性有关，也许可以通过学习某一未知映射，使之对一类或好几类图像信源具有最佳表示能力，但图像内容的高度复杂性与随机性限制了此映射的通用性。有关研究已表明，对训练集内的图像数据，BP 网络的压缩效果等价于零均值数据的 KLT 压缩效果，对训练集外的图像数据，压缩性能却差于 KLT，因此，冲破传统理论框架的束缚，对 BP 网络用于图像压缩编码的压缩机理进行进一步的研究十分必要的。

(2) 还未能找到适合图像数据高效压缩、充分利用视觉信息处理机制的神经网络模型，现有模型都是在模拟人脑功能的思想下建立的，没有考虑图像的特点和人眼的视觉机理，因此压缩效果不太理想。从理论上来说，神经网络可以模拟人眼的信息处理过程。这种模拟不限于网络结构方面，还包括网络的学习机制，但大多数神经网络的学习算法中，使用的只是均方误差或 P 阶误差失真准则，没有引入考虑人类视觉系统特性且使图像主客观质量评价一致的失真准则。另外，神经网络还未能发挥其强大的图像信息表征和处理功能，这也是基于神经网络的图像编码方法未能取得高压缩效率的一个原因。

(3) 现在计算机的计算能力和计算速度仍然不能满足中等以及大型结构的神经网络的计算要求，网络训练阶段的运算量大而计算机的运算速度又未跟上，这直接导致网络训练时间长，耗费的时间多，这是神经网络在图像压缩方面实际应用的一大障碍。

虽然神经网络在图像编码的应用中还存在许多待解决的问题，但短短几年在这个新的研究领域所取得的进展是令人鼓舞的，特别是 VLSI 技术的发展以及在神经网络实现上的广泛应用，已有一些基于神经网络的图像编码方法做成高速芯片投入使用，使图像编码的神经网络方法的实时实现变成现实。因此，我们认为，神经网络虽然不是灵丹妙药，可以解决图像编码技术中存在的任何问题，但作为实现图像编码的一种直接的或间接的新途径和新方法，其发展前景是令人乐观的。

致 谢

本论文是在唐治德教授的悉心指导下完成的，它凝聚着恩师的心血和学术思想。多年以来，恩师不仅在学业上对我严格要求，精心指点，更在生活上给了我无微不至的关心、支持和帮助。恩师精深的学术造诣，博大的思想体系，宽广的胸襟气魄是我一生学习的榜样和追求的目标。在学习和科研工作中唐老师不仅对我严格要求、循循善诱、悉心帮助，还特别注重了基础理论和方法论的指导。拓展一门新领域的研究要有系统的方法和理论的支持，在这方面，导师率先进行了相关领域的知识和理论综合，并指导我循序渐进地进行知识积累，使我在理论学习到具体实践，再到理论总结的过程中受益匪浅。导师渊博的学识、严谨踏实的治学态度、实事求是的科研作风以及对问题的独到见解和洞察力给我留下了深刻的印象，这将使我受益终身！在此，向唐老师表示深深的谢意，并致以崇高的敬礼！

感谢我的良师益友卢山同学，有了他的帮助，我的毕业设计才得以顺利进行，是他帮助我克服学习上的重重难关，是他让我面对问题时拓展思路、改变固有的思维方式，是他促使我积极进取和不断努力，他的指导和点拨使我受益匪浅并心存感激，在此向卢山同学致以深深的谢意！

感谢师兄聂代伟、师姐胡莎莉、同门左杨眉、师弟黄志鹏、郭远军、马超和唐林，师妹黄立华，他们在生活和学习上给予我许多关心和帮助；感谢同窗杨军、徐超、陈亮和好朋友张继红、惠娅倩、胡成志、林玉烽、王斌，我三年快乐的研究生生活离不开他们。

感谢我的父母，他们一定在天堂默默为我祈祷；感谢我的哥哥，他是我研究生生活中唯一的依靠和精神寄托，是他为我提供研究生生活的全部经济支持；感谢我的嫂子，她对我的关爱使我能够克服一切困难，在人生的道路上勇往直前，无所畏惧！感谢我的小侄女黄初秋，她给我和家人带来了无穷的欢乐和幸福，使我常常感受到生命的活力与希望！感谢我的挚友罗石惠，她多年来对我的关心、照顾、支持与鼓励，让我平寂的生活平添了很多温暖，这份友情值得我一辈子去珍惜。

最后，谨将本文献给所有在我求学过程中曾经关心和帮助过我的人，并再次感谢他们。

黄雪梅

2005年4月 于重庆

参 考 文 献

- [1] T.S.Huang, Picture bandwidth compression, Proc.Picture coding symposium(PSC'89), Gordon and Breach, 1972
- [2] 沈兰荪. 图像编码与异步传输. 人民邮电出版社. 2001 年
- [3] 夏正良. 数字图像处理. 东南大学出版社. 1999 年
- [4] 肖自美. 图像信息理论与压缩技术. 中山大学出版社. 2000 年
- [5] 吴乐南. 数据压缩的原理和应用. 电子工业出版社. 1995 年
- [6] 张益贞, 刘滔. Visual C++实现 MPEG/JPEG 编码解码技术. 人民邮电出版社. 2003 年
- [7] 钟玉琢, 王琪, 贺玉文著. 基于对象的多媒体数据压缩编码国际标准及其校验模型. 科学出版社. 2000 年
- [8] Martin T.Hagan, Howard B.Demuth, Mark H.Beale 著, 戴盔等译. 神经网络设计. 机械工业出版社. 2002 年
- [9] M.Kunt, Second generation image coding techniques, Proc IEEE, 1986, 73 (4): 549-574
- [10] W.E.Glenn, Digital image compression based on visual perception and scene properties, SMPTE Jour.1993, (3): 392-397
- [11] 杨长生. 图像与声音压缩技术.浙江大学出版社. 2000 年
- [12] 徐立中. 数字图像的智能信息处理. 国防工业出版社. 2001 年
- [13] 李劲, 林行刚, 吴佑寿. 神经网络与图像压缩编码. 通信学报. 1993. 14 (2): 84-89
- [14] 张乃尧, 阎平凡. 神经网络与模糊控制. 清华大学出版社. 1998: 1-9
- [15] 张立明. 人工神经网络的模型及其应用. 复旦大学出版社. 1993: 10-12, 32-33
- [16] Z.He, H.Li, Nonlinear predictive image coding with a neural network, Proc.ICASSP, Albuquerque, New Mexico, 1990: 1009-1012
- [17] S.A.Dianat, N.M.Nasrabadi, S.Venkataratnun, A non-linear predictor for differential pulse-code encoder(DPCM) using artificial neural networks, Proc.ICASSP, Toronto, 1991: 2793-2796
- [18] 张伟, 余英林, 鞠德航. 用于图像压缩编码的神经网络非线性预测器. 神经网络与信号处理会议论文集. 1991: 76-79
- [19] G.W.Cottrell, P.Munro, D.Zipser, Learning internal representations from gray-scale images: an example of extensional programming, Cognitive Science Soc. Annual Conf., 1989: 461-473
- [20] N.Sonehara, M.Kawato, S.Miyake, K.Nakane, Image data compression using neural network model, Proc.IJCNN, Washington DC, 1989: 35-41
- [21] R.Kohon, M.Arai, H.Imai, Image compression using a neural network with learning capability of variable function of a neural unit, Proc.SPIE, Lausanne, 1990, 1360: 69-76

- [22] M.Mougeot, R.Azencott, B.Augeniol, Image compression with back-propagation: improvement of the visual restoration using different cost functions, *Neural Networks*, 1991, 4: 467-476
- [23] S.Marsi, G.Ramponi, G.L.Sicutanta, Improved neural structures for image compression, *Proc.ICASSP*, Toronto, 1991: 2821-2824
- [24] G.Qiu, M.R.Varley, T.J.Tetrell, Image compression by edge pattern learning using multilayer perceptions, *Electronics Letters*, Apr.1993, 29 (7): 601-603
- [25] D.Cui, W.Wang, F.Wan, An unsupervised neural network algorithm for image compression, *Proc.SPIE*, San Diego, 1992, 1766: 720-725
- [26] A.J.Pinho, Image compression based on quadtree segmentation and artificial neural networks, *Electronics Letters*, May.1993, 29 (11): 1029-1031
- [27] M.Arozullah, A.Namphol, A data compression system using neural network based architecture, *Proc.IJCNN*, San Diego, 1990: 518-523
- [28] 张秀明, 张宏斌, 戴英侠. 图像数据压缩中的神经网络方法. 中国神经网络学术会议论文集. 1991: 545-548
- [29] F.Mekuria, Y.Fjailbraiu, Implementation of a fast codebook searching algorithm using a neural network model, *IEEE Symp.on CAS*, New Orleans, 1990: 1883-1886
- [30] N.M.Nasrabadi, Y.Feng, Vector quantization of images based upon the Kohonen self-organizing feature maps, *Proc.IEEE Int.Conf.Neural Networks*, 1988: 101-108
- [31] C.N.Manikopoulus, I.Li, Adaptive image sequence coding with neural network vector quantization, *Proc.IJCNN*, Washington DC, 1989: 573
- [32] K.K.Truong, R.M.Mersereau, Structural image codebooks and the self-organizing feature map algorithms, *Proc.ICASSP*, New Mexico, 1990: 2289-2292
- [33] A.K.Krishnamurthy, S.C.Ahalt, P.Chen, Neural networks for vector quantization of speech and images, *IEEE.J.Select Areas in Commun.*, Oct.1990, 8 (8): 1449-1457
- [34] T.C.Lee, A.M.Pererson, Adaptive vector quantization using a self development neural network, *IEEE.I.Select Areas in Commun*, Oct.1990.8 (8): 1458-1471
- [35] W.C.Fang, B.J.Shou, O.T.C.Chen, A real-time VLSI neuroprocessor for adaptive image compression based upon frequency-sensitive competitive learning, *Proc.IJCNN Seattle*, 1991: 429-435
- [36] 禹宏涛. 竞争学习的神经网络与图像矢量量化编码. 华中理工大学硕士学位论文. 1992年
- [37] C.N.Matukopoulos, G.Antoniou, S.Metzelopoulou, VQ of image sequence source and ANS classification of finite state machine for high compression coding, *Proc.IJCNN*, San Diego,

- 1990: 468-473
- [38] 陈衍仪. 图像压缩的分形理论和方法. 国防工业出版社. 1997 年
- [39] K.J.Falconer, The geometry of fractal sets, Cambridge Univ.Pr., 1985
- [40] 吴乐南. 数据压缩. 东南大学出版社. 2000 年
- [41] Y.Linde, A.Buzo, R.M.Gray, An algorithm for vector quantizer design, IEEE Trans. On Commun, 1980, 28 (1): 84-95
- [42] L.O.Chua, T.Lin, A neural network approach to transform image coding, Int. Circuit Theory and Applications, 1988, 16 (3): 317-324
- [43] A.Tabatabai, T.P.Troudet, A neural net based architechure for the segmentation of mixed gray-level and binary pictures, IEEE.Trans.CAS, 1991, 38 (1): 66-67
- [44] G.Qiu, M.R.Varley and T.J.Terrell, Improved block truncation coding using Hopfield neural network, Electronics, 1991,27 (21): 1924-1926
- [45] M.N.Pour, M.Hedge, F.Bourge, A compression of two neural network architectures for vector quantization, Proc.IJCNN, Seattle, 1991: 391-396
- [46] 王卫, 蔡德钧, 万发贯. DCT 编码的一种神经网络方法. 华中理工大学学报. 1993.21 (3): 98-103
- [47] 王卫, 蔡德钧, 万发贯. 基于 Hopfield 神经网络的平面拟合编码研究. 华中理工大学学报. 1994. 22 (10)
- [48] S.Carrato, Neural networks for image compression, Neural Networks: Adv. And Appl.2 ed., Gelenbe Pub, North-Holland, Amaterdam, 1992: 177-198
- [49] Abdel-Wahhab, O., and Fahmy, M.M., Image compression using multilayer neural networks, IEEE proc.Vis Signal Processing, vol.144, No.5, 1997 (10)
- [50] M.Mougeot, R.Azencott, B.Angeniol, Image compression with back propagation: improve of the visual restoration using different cost functions, Neural Networks, 1991, 4 (4): 467-476
- [51] 周继成. 人工神经网络第六代计算机的实现.科学普及出版社. 1993 年
- [52] 胡上序, 程翼宇. 人工神经元计算导论. 科学出版社. 1994 年
- [53] 靳蕃, 范俊波, 谭永东. 神经网络与神经计算机. 西安交通大学出版社. 1991 年
- [54] Benbenisti, New simple thre-layer neural network implication for image compression, 1997, 36: 1814-1817
- [55] J.Jiang, Image compression with neural networks—A survey, Proc.Image Processing: Image Communication, 1999, 14: 737-760
- [56] S.Carrato, Neural networks for image compression, Neural Networks: Adv. And Appl.2 ed., Gelenbe Pub, North-Holland, Amaterdam, 1992: 177-198
- [57] 刘永红. 神经网络理论的发展与前沿问题. 信息与控制. 1999 (1): 31-46

- [58] 张得富, 殷正坤. 人工神经网络的发展及其哲理. 科学技术与辩证法. 2000 (4): 17-20
- [59] Y.E.Yair, K.Zeger, and A.Gersho, Competitive learning and soft competition for vector quantizer design, IEEE Trans, Signal processing, 1992, 40 (2): 294-309
- [60] Liao X., Yu J., Robust stability for interval Hopfield neural networks with time delay, IEEE Transaction on neural networks, 1998, 9 (5): 1042-1045
- [61] Chao C., Kwang Y., Diagonal recurrent neural network for dynamic systems control, IEEE Transaction on neural networks, 1995, 6 (1): 144-156
- [62] 郑南宁. 计算机视觉与模式识别. 国防工业出版社. 1998: 49-78
- [63] 俞建定, 金炜. 用遗传 BP 网络进行图像边缘检测. 计算机工程与应用. 2003. 23 (39): 111-113
- [64] Cohen, M.A., Grossberg,S, Neural dynamics of brightness perception: Features, boundaries, diffusion, and resonance, Perception and Psychophysics, 1984, 428-456
- [65] S. Chartier, R. Proulx, A new online unsupervised learning rule for the BSB model, proc. LJCNN, 2001, 448-453
- [66] K.Y.Kin, J.B.Ra, Edge preserving vector quantization using self-organizing map based on adaptive learning, Proceedings of 1993 international joint conference on neural networks, 1993,1219-1222
- [67] K.Y.Kin, J.B.Ra, Adaptive learning method in self-organizing map for edge preserving vector quantization, IEEE Transaction on neural networks, 1995, 6 (1): 278-280

附录 A: 英文缩写

ANN:	Artificial Neural Network
ARTN:	Adaptive Resonance Theory Network
BP:	Back-Propagation
CCITT:	The International Telegraph and Telephone Consultative Committee
CPN:	Counter-propagation network
EPVQ:	Edges Preserved Vector Quantization
FSCL:	Frequency Sensitivity Competition Learning
ILNN:	Inner Loop Neural Network
ISNN:	International Symposium on Neural Network
JBIG:	Joint Bi-level Image Experts Group
JPEG:	Joint Photographic Expert Group
KLT:	Karhunen-Loeve Transform
LBG:	Linde, Buzo and Gray
LM:	Levenberg-Marquardt
MLPN:	Multi-Layer Perceptron Network
MPEG:	Moving Picture Expert Group
MSE:	Mean Square Error
NTA:	Nested Training Algorithm
OLNN:	Outer Loop Neural Network
PCS:	Picture Coding Symposium
PSNR:	Peak Signal to Noise Ratio
RBFN:	Radial Basis Functions Network
SA:	Simulated Annealing
SNR:	Signal to Noise Ratio
SOFM:	Self-Organizing Feature Map
SQ:	Scalar Quantization
VLSI:	Very Large Scale Integrated Circuits
VQ:	Vector Quantization

附录 B: Hopfield 网络的稳定性相关证明

定理 5.1 对于 Hopfield 网络, 若满足以下条件:

(a) $C_i > 0$; (b) $T_{ij} = T_{ji}$; (c) $g^{-1}()$ 单调递增且连续

则有 $\frac{dE}{dt} \leq 0$, 当且仅当对所有的 V_i 都满足 $\frac{dV_i}{dt} = 0$ 时, $\frac{dE}{dt} = 0$ 。

证明:

$$\frac{dE}{dt} = \sum_{i=1}^N \frac{\partial E}{\partial V_i} \frac{dV_i}{dt}$$

而

$$\begin{aligned} \frac{\partial E}{\partial V_i} &= -\frac{1}{2} \sum_{j=1}^N T_{ij} V_j - \frac{1}{2} \sum_{j=1}^N T_{ji} V_j - I_i + G_i u_i \\ &= -\frac{1}{2} \sum_{j=1}^N T_{ij} V_j + \frac{1}{2} \sum_{j=1}^N T_{ji} V_j - \sum_{j=1}^N T_{ji} V_j + G_i u_i - I_i \\ &= -\frac{1}{2} \sum_{j=1}^N (T_{ij} - T_{ji}) V_j - (\sum_{j=1}^N T_{ji} V_j - G_i u_i + I_i) \\ &= -\frac{1}{2} \sum_{j=1}^N (T_{ij} - T_{ji}) V_j - C_i \frac{du_i}{dt} \\ &= -C_i \frac{du_i}{dt} \frac{dV_i}{dt} \\ &= -C_i [g^{-1}(V_i)]' \frac{dV_i}{dt} \end{aligned}$$

故可以得出:

$$\frac{dE}{dt} = \sum_{i=1}^N -C_i [g^{-1}(V_i)]' \left(\frac{dV_i}{dt}\right)^2$$

因为 $C_i > 0$, $g^{-1}()$ 单调递增, 所以

$$\frac{dE}{dt} \leq 0$$

显然, 当且仅当对所有的 V_i 都满足 $\frac{dV_i}{dt} = 0$ 时, $\frac{dE}{dt} = 0$ 。

定理 5.2 在定理 5.1 的基础上, 若 $g()$ 进一步满足有界性的条件, 则当 Hopfield 网络处于 u 稳定时, 它一定处于 V 稳定。

证明:

$$V_i = g(u_i)$$

$$\text{故} \quad \frac{dV_i}{dt} = g'(u_i) \frac{du_i}{dt}$$

$$\text{由定义 5.1} \quad \frac{du_i}{dt} = 0 \quad (1 \leq i \leq N)$$

根据已知 $g'(u_i) > 0$

可以得出 $\frac{dV_i}{dt} = 0$ 亦即网络处于 V_i 稳定。

定理 5.3 在定理 5.1 的条件下, Hopfield 网络可以到达 u 稳定状态。

证明: 对 (5.8) 式: $C_i \frac{du_i}{dt} = \sum_{j=1}^N T_{ij} V_j - G_i u_i + I_i$ 两边求导可得,

$$C_i \frac{d^2 u_i}{dt^2} = \sum_{j=1}^N T_{ij} \frac{dV_j}{dt} - G_i \frac{du_i}{dt} \quad (1)$$

由于网络满足定理 5.1 的条件, 所以它一定可以达到 V 稳定状态, 也就是说, 在某个时刻 t_0 之后, 所有神经元的 V_i 不再随着时间的推移而发生变化, 即

$$\frac{dV_i}{dt} = 0 \quad (1 \leq i \leq N, t > t_0)$$

由此, 式 (1) 变为

$$C_i \frac{d^2 u_i}{dt^2} = -G_i \frac{du_i}{dt} \quad (2)$$

对式 (2) 求解可得,

$$u_i = k_{i1} + k_{i2} \lambda^{-\frac{G_i}{C_i} t}$$

由定理 5.1 的条件可知,

$$C_i > 0, \quad G_i = \frac{1}{R_i} + \sum_{j=1}^N |T_{ij}| > 0$$

可得出 $-\frac{G_i}{C_i} < 0$

由此可知, u_i 最终收敛。

又, 对任意神经元以上均成立,

所以, 网络可以到达 u 稳定状态。

附录 C：攻读硕士学位期间发表的论文

本文作者在攻读硕士学位期间发表的论文：

- [1] 基于多层前馈神经网络的图像压缩的仿真研究（计算机仿真，录用时间：2004.6.5）
- [2] BP 网络研究及其在肺癌诊断系统中的应用（重庆大学学报（自然科学版），Vol.28, No.1, 2005）
- [3] Study of BP Neural Network and Its Application in Lung Cancer Intelligent Diagnosis (the International Symposium on Neural Networks (ISNN2005), Lecture Notes in Computer Science, Vol:3498, April 2005, pp:774-779)
- [4] 用改进型 Hopfield 网络实现图像边缘检测（已投稿）
- [5] Vector Quantization Based on Visual Sensitivity to Image Edges（7th International Conference on Electronic Measurement & Instruments (ICEMI '2005)，录用时间：2005.4.15）

独 创 性 声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得重庆大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：黄圣梅

签字日期：2005 年 5 月 21 日

学位论文版权使用授权书

本学位论文作者完全了解重庆大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权重庆大学可以将学位论文的全部或部分内 容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

保密（☐），在 年解密后适用本授权书。

本学位论文属于

不保密（☒）。

（请只在上述一个括号内打“√”）

学位论文作者签名：黄圣梅

导师签名：唐治德

签字日期：2005 年 5 月 21 日

签字日期：2005 年 5 月 21 日